RLHF and RLVR in LLM Post-Training

摘要

大语言模型在海量无标注文本上通过预测下一个词元完成预训练后，虽然掌握了广泛的语言规律与世界知识，但其原始生成目标与人类实际交互需求及复杂逻辑推演目标之间仍存在显著偏差。围绕后训练（Post-Training）阶段如何利用反馈信号重塑模型行为，研究范式先后经历了从基于人类反馈的强化学习（Reinforcement Learning from Human Feedback，简称 RLHF）到基于可验证奖励的强化学习（Reinforcement Learning with Verifiable Rewards，简称 RLVR）的重要演进。本文系统梳理这两类后训练强化学习方法提出的核心动机、技术脉络、内在联系与适用边界。在基础方法层面，本文首先阐明自回归文本生成向序列决策过程的转化逻辑，分析策略梯度、优势估计、近端策略优化以及参考策略分布约束在稳定高维语言空间优化中的具体作用。随后，本文沿着从主观偏好对齐到客观结果验证的演进线索，剖析 RLHF 如何借助成对人类偏好与奖励模型解决开放域任务难以规则化评价的难题，探讨直接偏好优化对训练流程的简化及其离线分布局限，并揭示代理奖励过度优化这一促使研究转向客观验证的深层原因；继而深入考察 RLVR 如何利用数学答案核验与代码单元测试等确定性验证程序消除奖励模型偏差，以及群组相对策略优化、动态采样与无偏损失修正等方法如何支撑无监督微调冷启动下的长链推理演化。在此基础上，本文从奖励来源、过程与结果反馈粒度、评估可靠性及多阶段协同四个维度对比两类范式的利弊互补关系，并进一步围绕近期关于 RLVR 究竟只是提高已有路径采样效率还是实质扩展模型推理能力边界的学术争论展开深入辨析，总结持续强化学习所需的词元级探索维持、训练步数扩展、混合难度隐式课程以及跨学科生成式验证机制，最后展望大语言模型强化学习后训练的未来研究方向。

1 引言

1.1 研究背景：从语言建模到推理能力 + 提升偏好对齐

现代大语言模型（Large Language Models，简称 LLMs）的能力构建始于大规模自回归语言建模预训练（Pre-Training）。在预训练阶段，模型接收互联网网页、书籍、学术文献与程序代码等海量文本序列，在给定前文词元（Token）的条件下最大化下一个词元的预测对数似然。随着模型参数规模与预训练语料规模的持续扩大，这一看似简单的统计预测目标使模型习得了丰富的语法结构、跨学科事实知识以及初步的上下文模式归纳能力。然而，预测语料库中最可能出现的后续文本并不等同于按照用户意图高质量地完成任务，更不等同于执行严密可靠的多步逻辑推理。一方面，原始预训练语料混杂着质量参差不齐的表述、事实性错误乃至有害内容，

基座模型在面对用户提问时往往倾向于机械续写题目而非直接作答，难以自动遵循人类在有用性（Helpfulness）、真实性（Honesty）与无害性（Harmlessness）上的综合偏好[1-2]。另一方面，面对数学竞赛证明、复杂算法编程与科学分析等高难度问题，模型需要在给出最终结论前展开长跨度的中间推导、假设检验与自我纠错，而自然语料中很少完整记录人类思考过程中反复试错与修正的轨迹，仅靠模仿静态文本的下一词元预测难以充分激发深层推理潜力[3,2]。

为了弥补预训练语言建模目标与下游实际需求之间的差距，后训练（Post-Training）逐渐从辅助性的微调步骤演变为决定大语言模型能力表现的核心阶段。早期也是最直接的后训练手段是监督微调（Supervised Fine-Tuning，简称 SFT），即由人工撰写或筛选高质量的“指令—回复”示范样本，继续使用交叉熵损失训练模型模仿标准回答。监督微调能够以较低的计算成本教会模型理解对话格式与基本指令要求，但其固有的局限性也十分突出。首先，人工编写高质量长篇回答或严密多步推导过程的成本极高，示范数据的规模与复杂度受限于人类标注者的时间与专业水平；其次，监督微调在训练时强制模型在每一个词元位置拟合单一参考序列，模型只能被动记忆外部示范的表面分布，既无法从自身的错误生成中获知“错在何处”，也难以在自身预测分布内主动探索比人工示范更优的求解路径[1-2]。要让模型在缺乏逐词标准答案的场景下学会权衡回答优劣，或者在多步求解中通过自主尝试发现有效策略，就必须引入强化学习（Reinforcement Learning，简称 RL），使模型在自主采样生成完整回复后根据整体反馈信号调整生成概率。

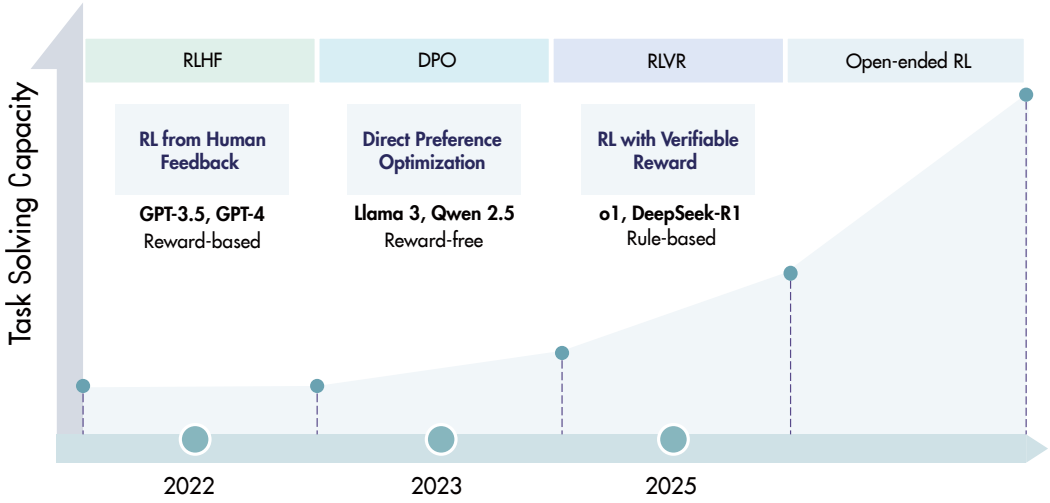


图 1： 大语言模型强化学习后训练范式的演进脉络：从早期面向人类偏好对齐的 RLHF 与免显式奖励模型的 DPO，逐步拓展至基于客观规则验证激发复杂任务求解与长链推理能力的 RLVR，并进一步朝向更通用的开放式强化学习方向演进（原图引自文献[2]）。

如图 1 所示，大语言模型强化学习后训练的发展历程清晰地呈现出两条相互衔接又各有侧重的技术主线[2]。第一条主线致力于提升人类偏好对齐水平，其代表范式是基于人类反馈的强化学习（Reinforcement Learning from Human Feedback，简称 RLHF）。在开放式问答、摘要撰写、创意写作与安全拒答等日常交互场景中，回答的优劣往往取决于表达清晰度、信息完备度与价值导向等主观综合维度，无法用固定程序规则直接打分。为此，Christiano 等人[4]与

InstructGPT[1]确立了“先采集人类对成对候选输出的主观偏好比较、训练神经网络奖励模型拟合人类评判标准，再通过强化学习最大化奖励模型评分”的技术路线，随后 Rafailov 等人提出的直接偏好优化（Direct Preference Optimization，简称 DPO）[5]进一步利用最优策略与奖励函数之间的解析映射省去了显式奖励训练环节，大幅降低了偏好对齐的工程门槛。

第二条主线则聚焦于突破复杂逻辑与科学任务的推理能力上限，其核心驱动范式是基于可验证奖励的强化学习（Reinforcement Learning with Verifiable Rewards，简称 RLVR）[6-7,3]。随着研究重心从日常对话转向竞赛级数学求解与高难度代码生成，传统 RLHF 所依赖的神经网络奖励模型暴露出严重的评估噪声与奖励欺骗（Reward Hacking）问题：在漫长的多步推导中，参数化的奖励模型极易被表面排版工整但关键算式错误的文本误导，导致策略模型在强化学习后期通过迎合评估漏洞获取虚假高分[8,3]。针对数学与编程等“求解过程复杂但最终结果客观可查”的任务属性，Tülu 3[6]、DeepSeekMath[7]以及 DeepSeek-R1[3]等代表性工作不再依赖主观偏好拟合，而是直接采用符号数学等价检验器、编译器与单元测试套件等确定性程序对模型最终输出给出精准无偏的验证反馈。实验表明，这种高可靠性的客观反馈支撑了更大规模的在线强化学习计算投入，使模型在无需人工逐步标注推导过程的前提下，自发演化出拉长思维链（Chain-of-Thought，简称 CoT）、检验中间结论以及推翻错误分支重新推导等复杂推理行为，从而开启了测试时计算扩展与训练时强化学习扩展协同演进的新阶段[3,2]。

1.2 本文范围与核心问题

本文聚焦于大语言模型后训练阶段中 RLHF 与 RLVR 这两类核心强化学习范式，旨在厘清二者从理论建模、算法设计到工程实践与前沿争论的完整逻辑脉络，而非罗列孤立的模型细节或工程技巧。为了便于读者准确把握全篇主线，本文围绕以下四个层层递进的核心问题展开论述。

第一个核心问题是：原本执行离散词元自回归预测的大语言模型，如何在统一的序列决策框架下接受标量奖励信号并实现稳定的参数更新？对此，第 2 节将阐明文本生成过程与马尔可夫决策过程的对应关系，剖析策略梯度定理、广义优势估计与近端策略优化（Proximal Policy Optimization，简称 PPO）[9]如何解决长序列高方差信度分配难题，并重点解释为何强化学习后训练普遍需要引入参考策略与分布散度约束来防止语言退化与过度优化[8,10]。

第二个核心问题是：面对无客观标准答案的主观交互任务与有确定性检验标准的客观推理任务，RLHF 与 RLVR 各自基于怎样的动机设计了不同的反馈获取机制与优化算法，又分别面临哪些固有局限？第 3 节将深入分析 RLHF 从成对偏好采集、Bradley-Terry 奖励建模[4,1]到 DPO 隐式奖励重参数化[5]的演化逻辑，剖析偏好标注噪声、离线分布偏移与代理奖励过度优化定律[8,10]对其扩展性的制约；第 4 节则转向 RLVR，阐述确定性验证函数的构造条件[6]、群组相对策略优化（Group Relative Policy Optimization，简称 GRPO）省去独立价值网络的动机与机制[7]、Tülu 3 与 DeepSeek-R1 系列多阶段训练流程的设计考量[6,3]，以及解耦截断与动态采样策略优化（Decoupled Clip and Dynamic sAmpling Policy Optimization，简称 DAPO）[11]和无偏群组相对策略优化（Dr. GRPO）[12]如何针对熵坍缩和长度偏差改进优化器。

第三个核心问题是：RLHF 与 RLVR 在整个后训练体系中究竟是替代关系还是互补关系，反馈粒度与奖励可靠性如何共同决定两者的协同方式？第 5 节将从奖励来源与适用任务边界出发，引入结果监督与过程监督这一正交的反馈粒度划分维度[13]，结合大规模训练中神经奖励模型的失效实证[3]，论证现代旗舰模型如何将客观可验证强化学习与人类偏好对齐有机整合在同一后训练流水线中[6,3]。

第四个核心问题是：近期引发广泛学术争论的“RLVR 究竟是否真正扩展了基座模型的推理能力边界”，应当如何在严谨的评估体系与训练动力学视角下加以理解？第 6 节将系统梳理基于多次采样通过率（Pass@k）与兼顾推导过程正确性的 CoT-Pass@k 评估方法[14-15]，对比“仅压缩分布提升采样效率”[14]与“长程训练及隐式激励实质拓展求解边界”[16,15]两派观点的实证依据，进一步从词元级低概率探索保护[17]、训练时长与参考策略重置[16]以及混合难度数据诱导的由易到难隐式课程[18]三个方面揭示持续强化学习的成立条件，并探讨如何借助基于参考答案的生成式软奖励验证器将 RLVR 推广至医学、法律与社会科学等自由文本领域[19]。最后，第 7 节对全文核心认识进行总结，并展望大语言模型强化学习后训练的未来研究方向。

2 大语言模型 RL 后训练的基本框架

2.1 从文本生成到序列决策

要将强化学习引入大语言模型后训练，首先需要解决一个建模层面的基本问题：大语言模型的本质是一个在固定词表 $\mathcal{V}$ 上按顺序逐个输出词元的条件概率分布，而强化学习处理的是智能体（Agent）在环境（Environment）中通过多步交互最大化累积回报的序贯决策问题。二者之所以能够无缝统一，关键洞见在于自回归文本生成的每一步词元采样本身就是一次依赖历史上下文的离散动作选择[2,12]。

具体而言，我们可以将大语言模型针对输入提示（Prompt）生成回复的过程严格表述为一个有限步长的词元级马尔可夫决策过程（Markov Decision Process，简称 MDP），记为五元组 $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$。在这一框架下，环境首先从任务提示分布 $\mathcal{D}$ 中采样一个由若干词元构成的输入问题或指令 $x = (x_1, x_2, \ldots, x_m)$，并将其作为初始状态 $s_1 = x$。由参数 θ 控制的大语言模型直接充当决策策略 π_θ。在生成过程的第 t 步（$t = 1, 2, \ldots, T$），策略模型观测到当前状态 $s_t = (x, y_{<t})$，其中 $y_{<t} = (y_1, \ldots, y_{t-1})$ 表示此前已经生成的词元前缀；随后，模型在整个词表空间 $\mathcal{A} = \mathcal{V}$ 上计算条件概率分布 $\pi_\theta(\cdot \mid s_t)$，并从中采样一个词元 $y_t \in \mathcal{V}$ 作为当前时间步的动作 $a_t = y_t$。动作一旦选定，环境便执行状态转移，将新生成的词元直接拼接到已有上下文末尾，得到下一步状态 $s_{t+1} = (x, y_{\le t})$。当模型采样到序列结束符（End-of-Sequence，简称 EOS）或者达到预设的最大生成长度上限 T 时，单轮生成轨迹终止，最终形成完整回复序列 $y = (y_1, y_2, \ldots, y_T)$。由此，策略模型给定提示 x 生成完整回复序列 y 的联合概率可表示为各步动作条件概率的连乘积：

$$\pi_\theta(y \mid x) = \prod_{t=1}^{T} \pi_\theta(y_t \mid x, y_{<t}). \tag{1}$$

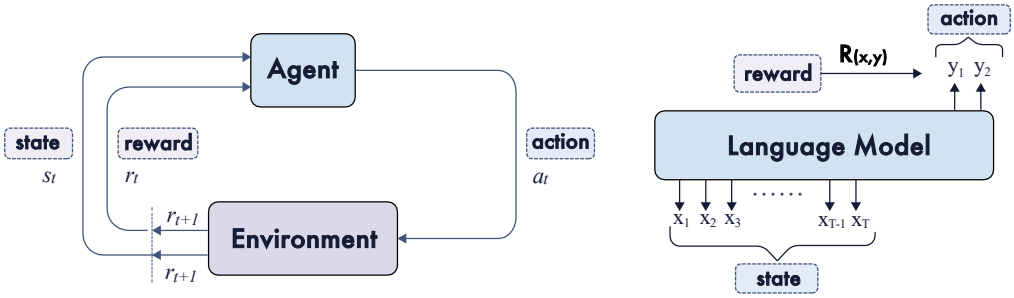


图 2： 经典强化学习交互回路（左）与大语言模型作为序列决策智能体（右）的结构对应关系：已生成的词元序列与输入提示共同构成当前环境状态，每一个新采样的词元对应一步离散动作，而评价生成质量的奖励信号通常在整个回复序列生成完毕后统一给出（原图引自文献[2]）。

如图 2 所示，将大语言模型看作序列决策智能体虽然在形式上遵循标准马尔可夫决策过程，但它与机器人控制或电子游戏等传统强化学习场景相比具有三个深刻影响后续算法设计的结构特征[2,12]。第一，状态转移函数 P 是完全确定且已知的纯文本拼接操作，环境中不存在外部物理随机扰动，所有的不确定性均来自初始提示采样以及策略 π_θ 自身的词元采样随机性。第二，动作空间维度极高且轨迹跨度极长：主流大语言模型的词表大小 $|\mathcal{V}|$ 通常在数万至十余万之间，而在复杂数学证明或代码生成任务中，一条包含完整思维链的回复长度 T 往往长达数千乃至数万个词元，这意味着可能的输出序列空间规模达到 $|\mathcal{V}|^T$ 量级，盲目随机搜索获得正确结果的概率几乎为零，强化学习必须依托预训练模型已有的先验语言分布才能有效开展探索。第三，奖励信号具有极端稀疏性与延迟性：无论是评估整段回答是否符合人类偏好，还是检验最终数学答案是否正确，外部评价函数通常只能在模型输出最后一个词元 y_T 后给出一个序列级标量总回报 $R(x, y)$，而在中间各个生成步骤 $t < T$ 上即时外部奖励均为零（在有限长文本生成中折扣因子通常取 $\gamma = 1$）。这种“数千步连续决策之后仅获得单一终端标量反馈”的结构，正是大语言模型强化学习后训练在信度分配（Credit Assignment）与方差控制上面临核心挑战的根源。

2.2 从奖励到参数更新：策略梯度、优势估计与 PPO

确立了序列决策建模之后，紧接着面临的问题是如何利用不可微的标量奖励 $R(x, y)$ 更新语言模型的连续网络参数 θ。由于词元序列 y 是通过离散采样操作从 $\pi_\theta(\cdot \mid x)$ 中生成的，与可微分的监督学习交叉熵损失不同，序列级奖励无法直接对模型输出层逻辑值（Logits）求导反向传播。强化学习通过优化期望累积回报 $J(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)}[R(x, y)]$ 绕开了这一障碍。借助对数导数恒等式 $\nabla_\theta \pi_\theta(y \mid x) = \pi_\theta(y \mid x) \nabla_\theta \log \pi_\theta(y \mid x)$ 并代入式 (1)，可以将期望回报对参数的梯度转化为对采样轨迹上各步词元对数似然梯度的加权求和，即经典的策略梯度（Policy Gradient）表达式[9,2]：

$$\nabla_\theta J(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)} \left[\sum_{t=1}^{T} \Psi_t \, \nabla_\theta \log \pi_\theta(y_t \mid s_t) \right]. \tag{2}$$

这里的权重项 Ψ_t 决定了第 t 个词元的生成概率应当被上调还是压低。最朴素的 REINFORCE 算法直接令 $\Psi_t = R(x, y)$，其直观含义十分清晰：凡是最终获得高奖励的回复序列，其中包含

的每一个词元概率都会沿着梯度方向同步增大；凡是获得低奖励的序列，其所有词元概率都会被同步削弱。

然而，在大语言模型长序列生成中直接使用原始回报 $R(x,y)$ 作为梯度权重存在两个严重缺陷。一方面，不同提示问题本身的难度差异极大，且原始奖励的数值基准未必居中（例如恒为正数），这会导致梯度估计方差极高，训练过程剧烈震荡；另一方面，一段长达数千词元的错误推理回复中往往包含大量正确的审题陈述与前期正确推导，而一段最终答对的回复中也可能夹杂冗余表述，将整条轨迹的单一终端得分无差别地赋予所有词元，会造成粗糙的信度分配。为了降低梯度方差并精细化衡量单步动作的净贡献，经典强化学习引入状态价值函数（Value Function）$V_\phi(s_t)$ 作为减方差基线（Baseline），用于预测在当前上下文前缀 s_t 下继续按当前策略生成直至结束所能获得的期望回报；进而定义优势函数（Advantage Function）$A_t = Q(s_t, y_t) - V(s_t)$，衡量当前选定的词元 y_t 相比于该状态下平均生成水平究竟好出多少或差出多少。在实际训练中，通常采用一个与策略网络规模相当的神经网络评论家模型（Critic Model）拟合 $V_\phi(s_t)$，并通过广义优势估计（Generalized Advantage Estimation，简称 GAE）结合单步时序差分误差 $\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$ 计算平滑优势估计量 $\hat{A}_t = \sum_{l=0}^{T-t} (\gamma\lambda)^l \delta_{t+l}$，其中超参数 $\lambda \in [0,1]$ 用于在低偏差的多步蒙特卡洛回报与低方差的单步价值估计之间取得平衡[9,7]。

即便有了优势估计，朴素同策略（On-Policy）梯度算法仍然面临采样效率低下与单步更新失稳的双重困境。大语言模型自回归逐词生成一批长回复需要消耗高昂的推理计算时间，如果每采集一批样本仅执行一次梯度更新就将其丢弃，硬件利用率将极其低下；但若在同一批旧策略 $\pi_{\theta_{\text{old}}}$ 采样的轨迹上反复执行多轮梯度更新，新策略 π_θ 与采样策略 $\pi_{\theta_{\text{old}}}$ 之间的重要性采样概率比 $r_t(\theta) = \frac{\pi_\theta(y_t|s_t)}{\pi_{\theta_{\text{old}}}(y_t|s_t)}$ 就会迅速偏离 1。一旦某些词元的概率比变得过大，过激的参数步长会瞬间破坏语言模型原本脆弱的词元预测分布，引发不可逆的性能崩溃，而早期的置信域策略优化（TRPO）虽然通过二阶共轭梯度法严格求解分布散度约束克服了这一问题，却因计算海森矩阵相关项开销过大而难以扩展到百亿参数规模的大语言模型[9]。

正是为了在不引入二阶优化复杂度的前提下实现安全的多轮样本复用，Schulman 等人提出了近端策略优化（PPO）算法[9]，奠定了此后数年大语言模型强化学习后训练的标准优化器基础。PPO 的核心洞见在于直接从目标函数层面截断过大策略更新带来的优化激励，其截断代理目标函数（Clipped Surrogate Objective）定义为：

$$J_{\text{PPO}}(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_{\theta_{\text{old}}}(\cdot|x)} \left[\frac{1}{|y|} \sum_{t=1}^{|y|} \min\Big(r_t(\theta)\hat{A}_t,\ \text{clip}\big(r_t(\theta), 1-\varepsilon, 1+\varepsilon\big)\hat{A}_t \Big) \right], \tag{3}$$

其中 $|y|$ 为生成序列长度，$r_t(\theta) = \frac{\pi_\theta(y_t|x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t|x, y_{<t})}$ 为第 t 个词元处的新旧策略概率比，$\varepsilon > 0$（通常取 0.2 左右）为控制信任区间宽度的截断阈值，$\text{clip}(u, 1-\varepsilon, 1+\varepsilon)$ 表示将数值 u 限制在区间 $[1-\varepsilon, 1+\varepsilon]$ 之内。

结合图 3 可以直观理解式 (3) 中逐点取最小值运算 $\min(\cdot,\cdot)$ 的精妙设计[9]。当某个词元的优势估计 $\hat{A}_t > 0$ 时，说明生成该词元带来了高于预期的回报，优化器应当增大 $\pi_\theta(y_t \mid s_t)$ 从而使 $r_t(\theta)$ 增长；但一旦 $r_t(\theta)$ 增长超过上限 $1+\varepsilon$，截断项 $(1+\varepsilon)\hat{A}_t$ 就会小于未截断项 $r_t(\theta)\hat{A}_t$，此时目标函数局部梯度归零，模型不再获得继续大幅推高该词元概率的梯度激励。反

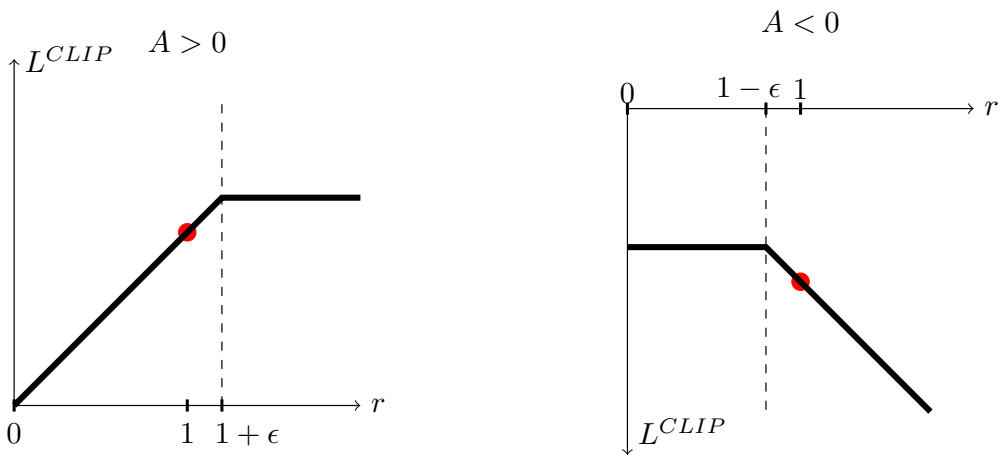


图 3: PPO 截断代理目标函数 L^{CLIP} 在单个时间步上随新旧策略概率比 r 的变化规律：左图对应优势估计为正（$A>0$）的情形，当概率比超过 $1+\varepsilon$ 后目标函数变平，阻止模型过度推高该动作概率；右图对应优势估计为负（$A<0$）的情形，当概率比低于 $1-\varepsilon$ 后目标函数同样停止增长，避免对单次负向样本施加过度惩罚（原图引自文献[9]）。

之，当 $\hat{A}_t < 0$ 时，优化器倾向于压低该词元概率使 $r_t(\theta)$ 减小；一旦 $r_t(\theta)$ 跌破下限 $1-\varepsilon$，目标函数同样因取下界而进入平坦区，防止单批采样中的偶发负样本将某些潜在有用的词元概率彻底清零（唯一例外是当旧策略更新导致 $r_t(\theta) > 1+\varepsilon$ 且 $\hat{A}_t < 0$ 等方向错误的情形时，取最小值操作仍保留未截断的线性梯度将策略拉回合理区间）。凭借仅需一阶随机梯度下降即可近似实现局部保守更新的优势，PPO 成功兼顾了计算可行性与多轮批处理的训练稳定性。不过，标准 PPO 需要同时在显存中维护策略模型与同等参数规模的价值模型 V_ϕ，这不仅带来了沉重的显存与通信开销，而且在仅有终端稀疏奖励的长思维链推理任务中，价值模型本身很难准确拟合数千步中间前缀的期望价值，这一固有矛盾直接催生了后续第 4 节中省去价值网络的组内相对优化方法[7,12]。

2.3 训练稳定性：参考策略与 KL Normalization

尽管 PPO 中的重要性采样截断机制限制了相邻两次迭代之间（即 π_θ 相对于上一轮 $\pi_{\theta_{\text{old}}}$）的单步更新幅度，但随着训练成百上千步地持续推进，每一步微小的分布变化不断累积，优化后的策略 π_θ 仍然可能远远偏离强化学习开始前的初始语言模型（通常为预训练基座或监督微调后的模型，统称为参考策略 π_{ref}）。在大语言模型强化学习后训练中，为了防止这种累积漂移破坏模型原有的语言生成能力并抵御不完美奖励信号的误导，几乎所有主流框架都会引入冻结参数的参考策略 π_{ref}，并通过库尔贝克—莱布勒散度（Kullback-Leibler Divergence，简称 KL 散度）对策略分布的变化幅度施加全局规范化约束——在目录表述中记为 KL Normalization，在强化学习后训练文献中通常称为 KL 散度正则化（KL Regularization）或 KL 惩罚约束[1,8,10]。纳入该分布约束后，大语言模型强化学习后训练的标准优化目标写为：

$$\max_{\theta} \ \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)}\big[R(x,y)\big] - \beta\, D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid x)\,\|\,\pi_{\text{ref}}(\cdot \mid x)\big), \tag{4}$$

其中正则化系数 $\beta \geq 0$ 控制着最大化任务奖励与保持参考策略先验分布之间的权衡强度，而序列级 KL 散度在自回归分解下等价于生成轨迹上各个词元位置条件对数概率比的期望累加，即 $D_{\mathrm{KL}}(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\mathrm{ref}}(\cdot \mid x)) = \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\big[\sum_{t=1}^{|y|} \log \frac{\pi_\theta(y_t|x,y_{<t})}{\pi_{\mathrm{ref}}(y_t|x,y_{<t})}\big]$。

为什么大语言模型在最大化奖励时不能任由策略自由演化，而必须时刻受到参考策略 π_{ref} 的分布约束？这一设计的提出源于两个层面的深刻动机。第一个动机是保持自然语言流畅度与预训练通用知识的完整性。如果完全撤除 π_{ref} 约束去极端最大化某个特定任务的标量奖励，模型极易退化出语法破碎、句式机械重复或丢失多领域常识的病态分布，因为只要这些非自然文本恰好能触发高奖励，无约束策略梯度就会将全部概率质量集中到极少数模式上[1,5]。第二个更为关键的动机则是抑制针对近似奖励模型的分布外投机优化。在以 RLHF 为代表的场景中，奖励信号 $R(x, y)$ 并非绝对客观的真实目标，而是由有限人类偏好样本训练出的神经网络代理奖励模型给出的预测值。该代理奖励模型仅在参考策略 π_{ref} 的常见输出分布附近具有较高的评估准确度；一旦待优化策略 π_θ 偏离 π_{ref} 过远，进入奖励模型在训练阶段从未见过的分布外区域，代理奖励模型的预测误差就会急剧放大，策略优化器便会专门搜寻并放大那些代理评分极高但实际质量低劣的异常输出[8,10]。

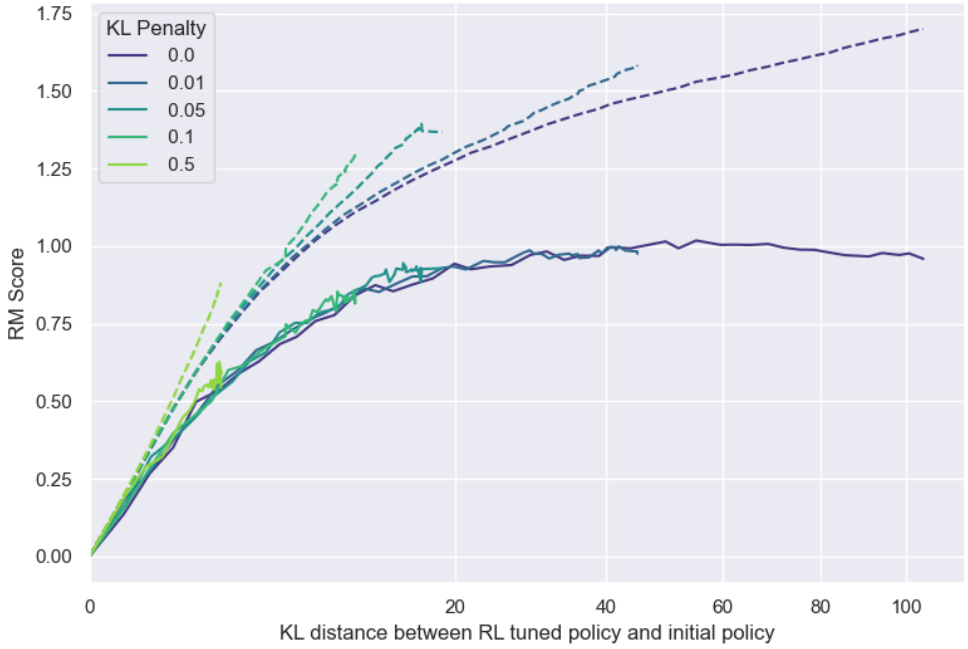


图 4： 不同 KL 惩罚系数 β（图中记作 KL pen）下强化学习训练过程中策略与初始参考分布距离 $\sqrt{\mathrm{KL}}$ 同奖励得分之间的关系：实线代表真实金标准奖励得分，虚线代表代理奖励模型评分。当 $\beta = 0$ 时策略偏移极大且代理得分与真实质量严重背离；增大 β 可将收敛点约束在真实奖励较高的安全散度区间内（原图引自文献[8]）。

Gao 等人[8]通过严密的受控实验清晰展示了 KL 散度约束的作用机理与边界，如图 4 所示。当完全不施加 KL 惩罚（$\beta = 0$）时，随着训练推进，策略相对于参考策略的分布偏移距离持续增大，虚线所示的代理奖励评分一路攀升，但实线所示的真实金标准奖励在达到峰值后迅速大幅回落；而随着惩罚系数 β 逐步增大，策略演化的最终散度上界被有效收紧，模型得以停

留在真实奖励较高的分布区间内。值得注意的是，图中不同 β 对应的实线轨迹几乎重合在同一条曲线上，这一现象揭示了一个重要洞见：显式的 KL 惩罚在代理奖励优化中本质上起到了自适应控制分布偏移半径（类似于受控早停）的作用，它通过限制策略远离 π_{ref} 的幅度来规避分布外奖励失真，但并不能消除代理奖励模型本身的建模偏差[8]。

在具体的工程实现中，施加 KL 约束主要有两种方式。第一种是 InstructGPT[1] 与 Tülu 3[6] 等工作采用的“奖励内扣法”，即在每个词元时间步将对数概率比 $-\beta \log \frac{\pi_\theta(y_t|s_t)}{\pi_{\text{ref}}(y_t|s_t)}$ 直接叠加到即时奖励中参与优势函数计算；第二种是 DeepSeekMath[7] 与 DeepSeek-R1[3] 等工作采用的“损失函数直接正则化法”，即将总损失中的 KL 项写为无偏且恒非负的估计量 $\frac{\pi_{\text{ref}}(y_t|s_t)}{\pi_\theta(y_t|s_t)} - \log \frac{\pi_{\text{ref}}(y_t|s_t)}{\pi_\theta(y_t|s_t)} - 1$ 直接求梯度，避免奖励缩放因子扭曲优势估计。有趣的是，随着后训练范式从 RLHF 发展到基于客观规则验证的 RLVR，学术界对 β 的取值策略出现了新的分化：由于规则验证器不存在神经网络代理模型的分布外评估失真问题，DAPO[11] 与 Dr. GRPO[12] 等从基座模型出发训练长链推理的工作主张直接令 $\beta = 0$，以释放模型演化出长思维链所需的分布变化空间并节省加载 π_{ref} 的显存开销；而延长强化学习方法 ProRL（Prolonged RL）[16] 的研究则指出，在超长步数的多任务强化学习中，完全取消 KL 约束仍易诱发策略过早陷入局部窄分布，保留适度的 KL 约束并配合周期性重置参考策略，才能在训练稳定性与远距离探索之间取得更优平衡。

3 RLHF：从人类偏好中学习

3.1 人类反馈的采集与偏好奖励模型

强化学习之所以长期局限于棋类博弈与规则明确的模拟控制环境，根本原因在于绝大多数现实世界任务无法手工编写精确的标量奖励函数。以大语言模型面对的开放式摘要撰写、多轮情感支持、复杂概念解释以及伦理安全应对为例，一段回答的好坏同时取决于事实准确性、条理清晰度、语气得体程度以及潜在危害规避等多个主观维度，任何基于词频统计或表面重叠率（如 BLEU、ROUGE）的手工评价指标一旦被模型当作强化学习目标直接最大化，都会迅速诱发违背人类真实意图的畸形文本。为了打破奖励函数难以显式形式化的限制，Christiano 等人[4] 提出了从人类偏好中开展深度强化学习的经典框架，确立了一条关键洞见：尽管人类很难为单条复杂行为轨迹直接给出跨样本一致的绝对分值，也难以亲自示范最优决策序列，但当面对同一问题下的两条候选结果时，人类能够以极低的认知负担且较高的信度判断“哪一个结果更好”。

如图 5 所示，这一机制通过“人类比较标注—奖励模型拟合—策略强化优化”三个异步协同的环节，将稀疏离散的人类主观判断转化为稠密可计算的训练信号[4]。在大语言模型场景中，系统首先针对同一输入提示 x 从当前模型采样出两条或多条候选回复，交由人类标注员阅读并标记出更受偏爱的胜出回复 y_w（Winner）与相对逊色的落败回复 y_l（Loser），由此构建成对偏好数据集 $\mathcal{D}_{\text{pref}} = \{(x, y_w, y_l)\}$。之所以普遍采用相对排序而非绝对打分（如 1 至 10 分量表），是因为不同标注员对分值宽严尺度的主观理解存在巨大个体差异，同一标注员在长时间工作后打分基准也会发生漂移，这种尺度噪声会直接污染奖励信号；而成对优劣比较消除了绝对量纲差异，显著提高了跨标注员的一致性[1,10]。

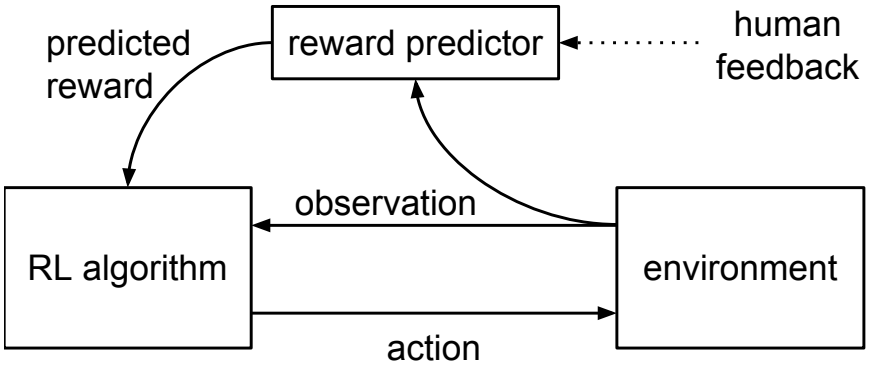


图 5: 从人类成对偏好比较中学习奖励模型并指导强化学习策略优化的闭环机制：策略智能体与环境交互生成行为轨迹片段，人类标注者对成对候选结果给出相对优劣判断，奖励预测网络异步拟合人类潜在偏好函数并向策略优化器持续提供标量训练信号（原图引自文献[4]）。

为了从离散的成对比较标签 $y_w \succ y_l$ 中还原出连续标量奖励函数，RLHF 引入统计学中的 Bradley-Terry 成对比较模型[4,10]。具体而言，构建一个以参数 ψ 控制的神经网络奖励模型（Reward Model，简称 RM）$r_\psi(x, y)$，该网络通常直接由经过监督微调的语言模型改造而来，只需将其原本输出词表分布的线性预测头替换为一个输出单一实数的标量回归头，并取输入序列最后一个结束词元位置的输出值作为整段回复 (x, y) 的综合评分[1]。Bradley-Terry 模型假设，人类认为回复 y_w 优于 y_l 的概率取决于两者潜在奖励分值之差经过逻辑斯蒂函数（Sigmoid 函数，$\sigma(z) = (1 + e^{-z})^{-1}$）映射后的结果：

$$P(y_w \succ y_l \mid x) = \sigma\big(r_\psi(x, y_w) - r_\psi(x, y_l)\big) = \frac{1}{1 + \exp\big(-\big(r_\psi(x, y_w) - r_\psi(x, y_l)\big)\big)}. \tag{5}$$

基于上述概率模型，可以通过在偏好数据集 $\mathcal{D}_{\text{pref}}$ 上最小化负对数似然损失来端到端训练奖励模型参数 ψ：

$$\mathcal{L}_{\text{RM}}(\psi) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}}\Big[\log \sigma\big(r_\psi(x, y_w) - r_\psi(x, y_l)\big)\Big]. \tag{6}$$

值得深入剖析的是，将人类反馈压缩进参数化奖励模型 $r_\psi(x, y)$ 之所以高效，核心在于利用了预训练语言模型内部已有的语义表征实现跨样本泛化。在 Christiano 等人[4]的早期实验中，仅需不到 1% 的环境交互步数接入真实人类反馈，学习到的奖励模型便能支撑智能体习得复杂控制行为；而在 InstructGPT[1]中，标注员可以一次性对同一提示下的 K（例如 $K = 4$ 至 9）条候选回复进行完整排序，一次审阅即可组合出 $\binom{K}{2}$ 个成对比较样本放入同一训练批次中联合计算损失，既大幅提升了人类标注吞吐效率，又有效防止奖励模型对单一提示过拟合。不过，从统计建模视角来看，式 (6) 仅依赖于奖励差值 $r_\psi(x, y_w) - r_\psi(x, y_l)$，这意味着奖励函数对于任意仅依赖提示 x 的平移项 $c(x)$ 具有等价不变性，必须在训练后对奖励输出做零均值归一化处理；同时，单一标量分值隐含了人类群体偏好满足传递性且高度同质的强假设，当不同文化背景或专业领域的标注员对同一回答持有截然相反的评价时，Bradley-Terry 模型只能将其折中拟合为中间概率，从而限制了奖励模型对多元异质偏好的表达精度[10]。

3.2 经典训练流程：以 InstructGPT 为例

如果说早期偏好学习验证了“用奖励模型替代手工奖励”的可行性，那么 Ouyang 等人提出的 InstructGPT[1] 则真正将这一思想工程化为现代大语言模型后训练的标准三阶段流水线，首次在百亿至千亿参数规模上证明：模型能否让真实用户满意，主要取决于后训练阶段的意图对齐质量，而非单纯取决于预训练参数规模的盲目扩张。

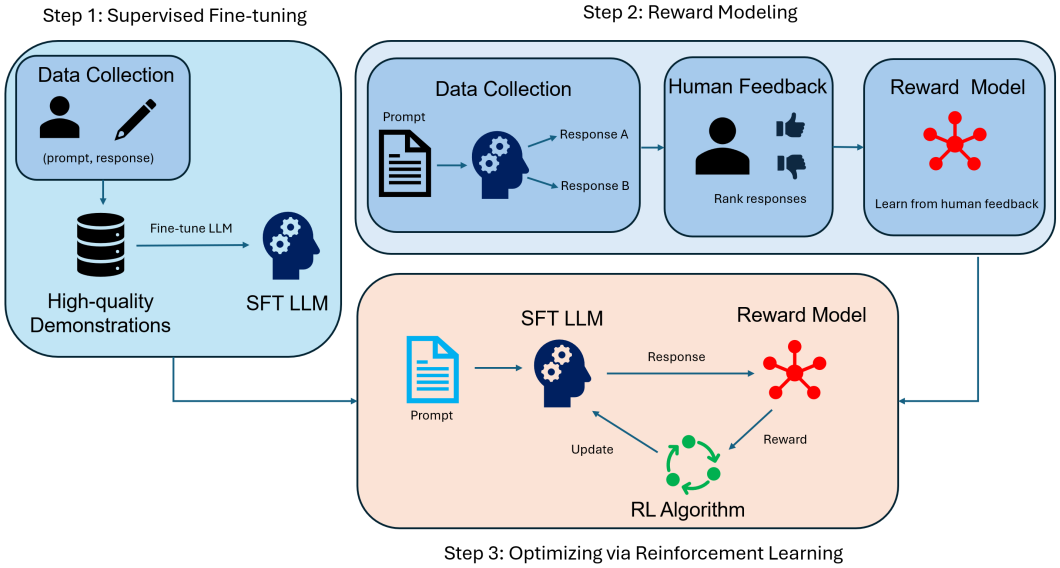


图 6： 以 InstructGPT 为代表的经典 RLHF 三阶段训练流程：第一阶段利用高质量示范数据执行监督微调获得具备基本对话遵循能力的初始模型；第二阶段采集同一提示下多条候选回复的人类偏好排序并训练标量奖励模型；第三阶段以监督微调模型为起点与参考基准，利用 PPO 在线最大化奖励模型评分（原图引自文献[10]）。

如图 6 所示，经典 RLHF 训练流程由环环相扣的三个阶段组成，每一个阶段的引入都有着明确的必要性[1,10]。第一阶段是监督微调（SFT）：研究团队收集真实用户提交的多样化指令提示，由经过筛选与培训的标注员人工撰写高质量示范回复，在预训练基座 GPT-3 上开展监督微调。这一阶段之所以不可或缺，是因为原始预训练基座的默认生成分布距离规范指令回答过远，若直接在其上开展在线采样与偏好标注，绝大多数候选输出都将是答非所问的续写文本，强化学习很难从中捕捉到有效的正向梯度；监督微调相当于以较低成本将策略分布快速引导至合理的对话回复区域，为后续阶段提供可靠的初始化起点。第二阶段是奖励模型训练（RM）：利用第一阶段所得模型针对大量提示采样多条不同回复，由人工按综合有用性、真实性与无害性进行排序，依照式 (6) 训练出一个能够代表人类评判标准的奖励网络 $r_\psi(x, y)$（InstructGPT 中采用 60 亿参数的奖励模型，以兼顾评估容量与在线推理开销）。第三阶段是基于 PPO 的强化学习微调：以第一阶段的监督微调模型作为初始策略 π_θ，同时冻结其参数副本作为参考策略 π_{ref}，在更大规模的无人工答案提示集上不断在线采样回复、调用奖励模型打分并按 PPO 算法更新策略参数。

在实际推进第三阶段强化学习时，InstructGPT 发现了一个极具普遍意义的现象：单纯最大化人类对话偏好奖励并施加 KL 惩罚，虽然能大幅提升开放式指令遵循表现，却会导致模型

在多项传统公开自然语言处理基准（如问答、阅读理解与翻译任务）上的零样本或少样本准确率出现明显下滑，文献将其称为“对齐税”（Alignment Tax）[1]。之所以产生对齐税，是因为对话偏好强化学习过度强化了特定交互句式，对预训练阶段习得的广泛通用分布造成了局部遗忘。为了消除这一负面效应，InstructGPT 在标准 KL 正则化强化学习目标之上混入了原始预训练语料分布 $\mathcal{D}_{\text{pretrain}}$ 上的自回归对数似然梯度，构造出著名的 PPO-ptx 联合优化目标[1]：

$$J_{\text{PPO-ptx}}(\theta) = \mathbb{E}_{(x,y)\sim\mathcal{D}_{\pi_\theta}}\left[r_\psi(x,y) - \beta\log\frac{\pi_\theta(y\mid x)}{\pi_{\text{ref}}(y\mid x)}\right] + \gamma_{\text{ptx}}\,\mathbb{E}_{x_{\text{pre}}\sim\mathcal{D}_{\text{pretrain}}}\left[\log\pi_\theta(x_{\text{pre}})\right], \quad (7)$$

其中 $\gamma_{\text{ptx}} \geq 0$ 为控制预训练语言建模损失权重的超参数。这一简洁的混合梯度设计在不牺牲人类偏好胜率的前提下，成功恢复甚至超越了原始基座模型在公开学术基准上的性能。

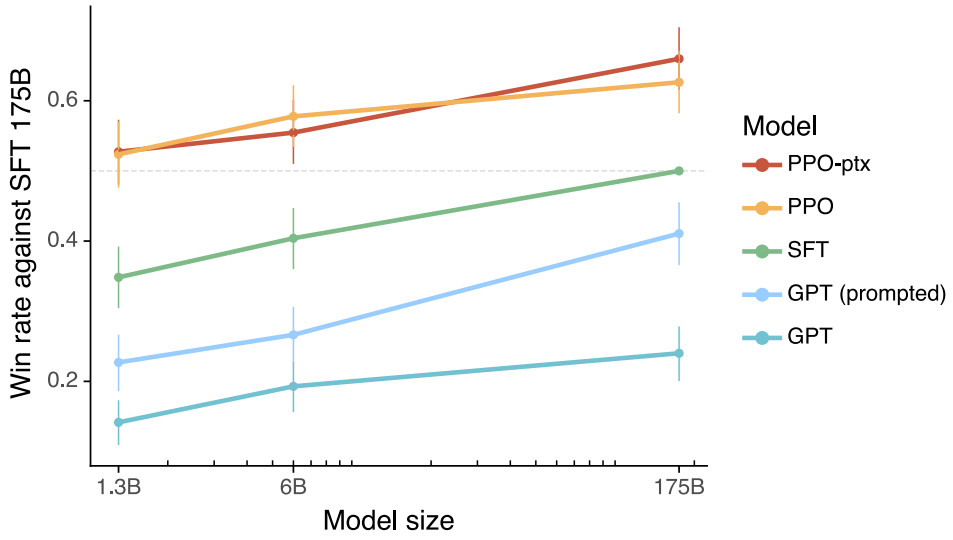


图 7： 不同参数规模（13 亿、60 亿与 1750 亿）下原始 GPT-3、提示工程版 GPT-3、监督微调模型（SFT）以及强化学习对齐模型（PPO 与 PPO-ptx）在真实用户指令分布上的人类评估偏好胜率对比（原图引自文献[1]）。

图 7 展示了 InstructGPT 最具启发性的实证结果[1]。在涵盖广泛真实用户意图的盲测对比中，仅拥有 13 亿参数的 PPO-ptx 模型所获得的标注员偏好胜率，已经显著超越了参数量高达 1750 亿（相差逾百倍）的原版 GPT-3；而在同等 1750 亿参数规模下，经过 RLHF 训练的模型在 $85\% \pm 3\%$ 的测试样本上被认为优于原版 GPT-3，即便与精心设计少样本提示的 GPT-3 相比胜率仍超过 70%，同时捏造事实的幻觉比例与有害输出比例均显著下降，甚至将主要在英文偏好数据上习得的指令遵循习惯自发泛化到了非英语语言与代码任务上。更值得思考的是为什么第三阶段的强化学习能够显著超越第一阶段的监督微调（图中橙色与紫色曲线始终大幅高于绿色 SFT 曲线）：监督微调迫使模型把概率质量平摊到人工示范的每一个具体用词上，一旦推理生成偏离示范轨迹便缺乏纠偏能力；而 RLHF 在模型自身在线采样出的真实分布上评价整段回复的综合效果，允许模型保留自身擅长的内部知识组织方式，只需增强高评价回复的整体生成概率并抑制低质量模式，从而以远低于大规模扩充预训练语料的经济成本激发出了基座模型潜藏的任务完成能力。

3.3 直接偏好优化：DPO 与经典 RLHF 的联系

尽管以 InstructGPT 为代表的三阶段 RLHF 取得了巨大成功，但其在系统工程与优化稳定性上的代价也极为高昂。在实际训练一套千亿参数模型的 PPO 流水线时，训练集群必须同时在显存中驻留四个大规模神经网络：正在更新参数的策略模型 π_θ、同步训练的价值评论家网络 V_ϕ、冻结参数的参考模型 π_{ref} 以及冻结参数的奖励模型 r_ψ。不仅如此，强化学习循环中的在线自回归长文本生成存在严重的推理延迟，且策略梯度与价值估计对学习率、批次大小、优势归一化与截断阈值等超参数高度敏感，极易在训练中途发生损失发散或模式崩溃。这就引出了一个深刻的理论追问：既然最终目标是让语言模型符合成对人类偏好数据 $\mathcal{D}_{\text{pref}}$，我们是否真的必须先训练一个显式奖励模型，再通过复杂的在线强化学习去近似优化它？

Rafailov 等人提出的直接偏好优化（DPO）[5] 通过对 KL 正则化强化学习目标进行严谨的数学等价变换，给出了否定的回答。DPO 的核心洞见在于：式 (4) 所定义的带 KL 散度约束的奖励最大化问题，在泛函变分意义下实际上存在唯一且可解析表达的闭式最优策略（Closed-Form Optimal Policy）。具体而言，对于任意给定的奖励函数 $r(x, y)$ 与参考策略 $\pi_{\text{ref}}(y \mid x)$，令目标泛函对分布变分为零，可直接求得全局最优策略分布 $\pi_r(y \mid x)$ 满足玻尔兹曼分布形式：

$$\pi_r(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad \text{其中} Z(x) = \sum_{y'} \pi_{\text{ref}}(y' \mid x) \exp\left(\frac{1}{\beta} r(x, y')\right). \tag{8}$$

式 (8) 中的配分函数（Partition Function）$Z(x)$ 需要遍历整个指数级庞大的所有可能回复序列求和，直接计算在数值上是完全不可行的。然而，如果我们反过来用最优策略 $\pi_r(y \mid x)$ 去反解潜在的奖励函数 $r(x, y)$，对式 (8) 两端取对数移项即可得到重参数化关系：

$$r(x, y) = \beta \log \frac{\pi_r(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x). \tag{9}$$

当我们将式 (9) 代入式 (5) 所示的 Bradley-Terry 成对偏好概率模型 $P(y_w \succ y_l \mid x) = \sigma(r(x, y_w) - r(x, y_l))$ 时，关键的代数化简随之发生：由于胜出回复 y_w 与落败回复 y_l 对应同一个输入提示 x，两者奖励表达式中难以计算的配分函数项 $\beta \log Z(x)$ 在相减时被精确抵消[5]。由此，成对人类偏好概率可以直接由待优化语言模型 π_θ 与参考模型 π_{ref} 的序列生成概率比唯一决定，无需引入任何额外奖励网络，直接最小化偏好负对数似然即可得到著名的 DPO 损失函数：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right) \right]. \tag{10}$$

对式 (10) 求参数梯度可以进一步看清 DPO 的内部更新机制。记隐式奖励为 $\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$，则损失梯度写为[5]：

$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\beta\, \mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}} \Big[\sigma\big(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)\big) \big(\nabla_\theta \log \pi_\theta(y_w \mid x) - \nabla_\theta \log \pi_\theta(y_l \mid x) \big) \Big]. \tag{11}$$

由此可见，待优化语言模型与参考模型的对数概率比直接充当了隐式奖励函数：DPO 在增大胜出回复对数似然的同时减小落败回复对数似然，并且自动赋予那些当前隐式奖励将优劣顺序

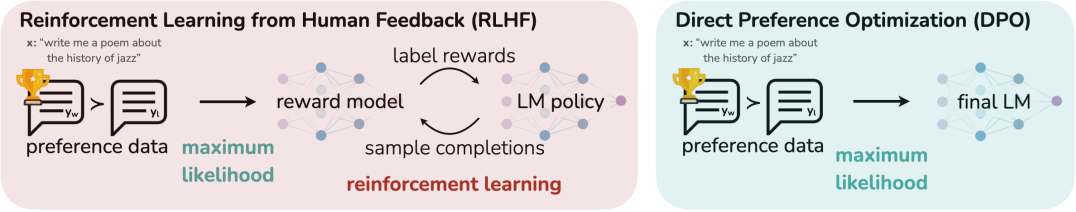


图 8: 经典两阶段偏好建模加强化学习（左）与直接偏好优化 DPO（右）的范式对比：DPO 利用最优策略与奖励函数之间的解析一一对应关系，将强化学习策略优化转化为在静态成对偏好数据上直接优化的二元交叉熵损失，彻底省去了独立奖励模型与在线采样循环（原图引自文献[5]）。

判反样本对更大的梯度权重——这一自适应加权十分关键，作者证明若去掉该权重退化为简单拉大正负样本似然差，模型生成质量会立即严重退化。如图 8 与图 9 所示，凭借这一理论等价性，DPO 仅需在显存中保留策略模型与参考模型（甚至可预先缓存 π_{ref} 的对数概率从而只驻留单个模型），完全用稳定的监督式批梯度下降取代了在线采样与价值网络拟合，不仅在正面情感控制任务上取得了优于 PPO（即便给 PPO 提供真实奖励真值）的期望奖励—KL 散度帕累托前沿，而且在长文本摘要等任务上对解码采样温度变化展现出比 PPO 更强的稳健性[5]。

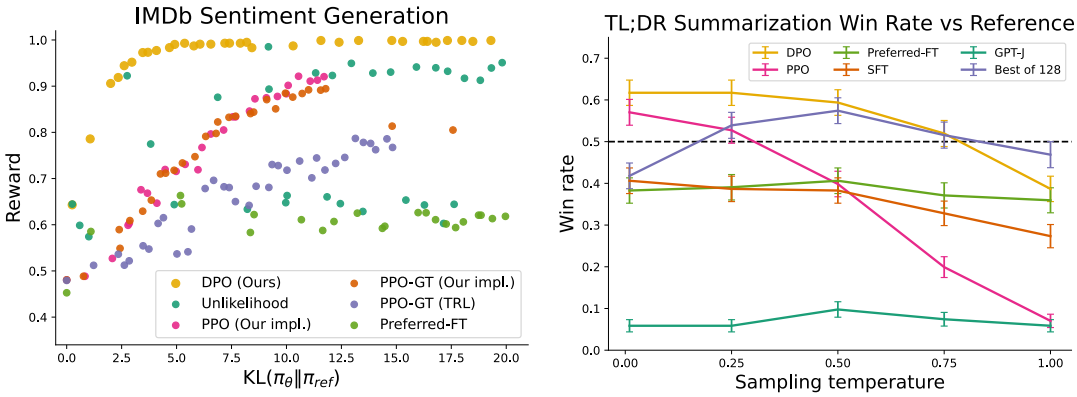


图 9: DPO 与经典 RLHF 方法的实证表现对比：左图展示在情感控制生成任务中，DPO 在不同正则化系数下取得了更高的期望真实奖励与更低的参考策略 KL 散度；右图展示在 TL;DR 文本摘要任务中，DPO 在不同解码采样温度下的人类评估胜率全面优于 PPO 与监督微调基线（原图引自文献[5]）。

正是由于极高的训练效率与超参数鲁棒性，DPO 迅速在 Llama 3、Qwen 2.5 与 Tülu 3[6,2] 等主流开源模型后训练中获得广泛采用。然而，DPO 的理论等价性建立在偏好数据充分覆盖策略探索空间的理想假设之上，其离线（Offline）优化属性也带来了新的固有折中[10,2]。由于训练期间不再根据当前 π_θ 在线采样新回复，随着参数不断更新，π_θ 的实际输出分布会逐渐偏离最初采集静态偏好集 $\mathcal{D}_{\text{pref}}$ 时的采样分布，导致模型在自身真实高概率生成区域缺乏直接对比监督；此外，在某些偏好对高度相似的离线数据上，DPO 有时会出现胜出回复与落败回复的绝对生成概率同时下降（只是落败回复降得更快从而使差值仍增大）的似然挤压现象，反过来把部分概率质量挤向未出现在偏好集中的分布外序列。因此，后续研究普遍探索在训练过程中多轮

重新采样构建准在线（Iterative / On-Policy）DPO 数据[6]，或者在需要深度自主探索的复杂推理场景中重新回归在线强化学习范式。

3.4 主要局限

纵观整个 RLHF 技术体系（无论采用显式奖励模型的在线 PPO 还是隐式奖励重参数化的离线 DPO），尽管它在对齐人类日常交流偏好与安全规范方面表现卓越，但当业界试图将其进一步推向更高训练算力规模以及更严密的逻辑推理任务时，其底层机制暴露出四项难以仅靠微调算法细节彻底根除的结构性局限[8,10,3]。

第一项局限在于人类偏好数据采集的高昂成本与固有认知偏差。在日常闲聊或简短摘要任务中，普通标注员可以在数分钟内完成成对回复比较；但当问题涉及研究生水平的数学定理证明、大型软件工程跨文件调试或前沿生物医学文献推理时，雇佣具备相应专业能力的人类专家逐行核查两条数千词推导过程的真伪，在时间与资金上都难以实现百万量级的规模扩展[6,3]。更为棘手的是，当任务难度超出标注员的即时验证能力时，人类反馈会不可避免地退化为对表面文风的偏好——标注员更容易青睐排版清晰、语气自信、篇幅详尽但暗藏细微逻辑谬误或事实幻觉的回答，而给简短生硬却完全正确的回答打出低分，这种系统性标注偏差会直接误导模型习得迎合表象而非追求事实真值的生成倾向[1,10]。

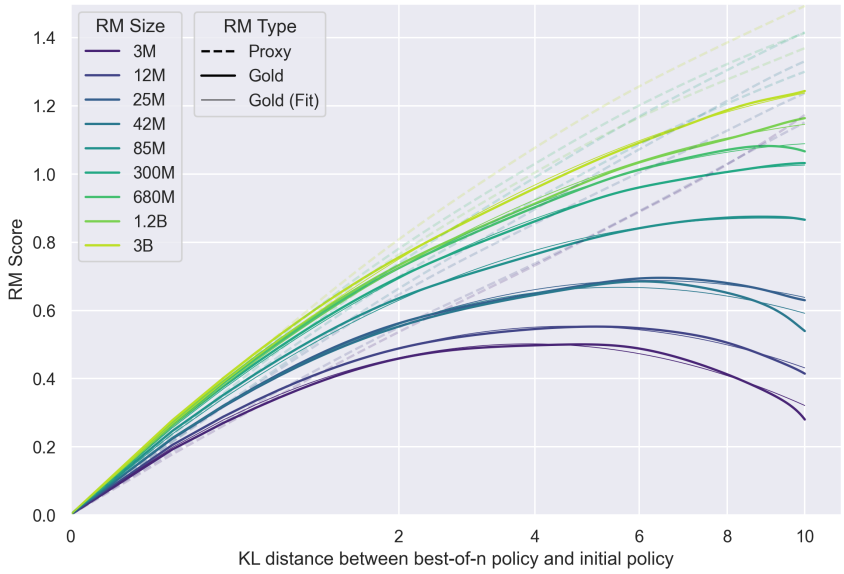
第二项也是最具根本性的局限，是神经网络代理奖励模型的过度优化（Reward Model Overoptimization）与奖励欺骗（Reward Hacking）现象[8]。在 RLHF 中，策略优化的直接对象始终是有限样本训练出的近似代理奖励模型 r_ψ，而非人类心中不可观测的真实效用函数。根据古德哈特定律（Goodhart's Law），当一个近似统计指标被施加强大优化压力当作绝对目标最大化时，它就不再是一个可靠的度量指标。Gao 等人[8]利用大规模合成金标准奖励模型系统揭示了这一过程的定量标度律（Scaling Laws）：记优化后策略 π 相对于初始参考策略 π_{ref} 的分布偏移距离平方根为 $d \triangleq \sqrt{D_{\text{KL}}(\pi \,\|\, \pi_{\text{ref}})}$，在强化学习优化过程中，尽管代理奖励模型给出的预测分值随 d 单调持续上升，但真实金标准奖励增益 $R_{\text{gold}}(d)$ 却严格遵循先升后降的凹函数规律：

$$R_{\text{gold}}(d) = d\big(\alpha - \eta \log d\big), \tag{12}$$

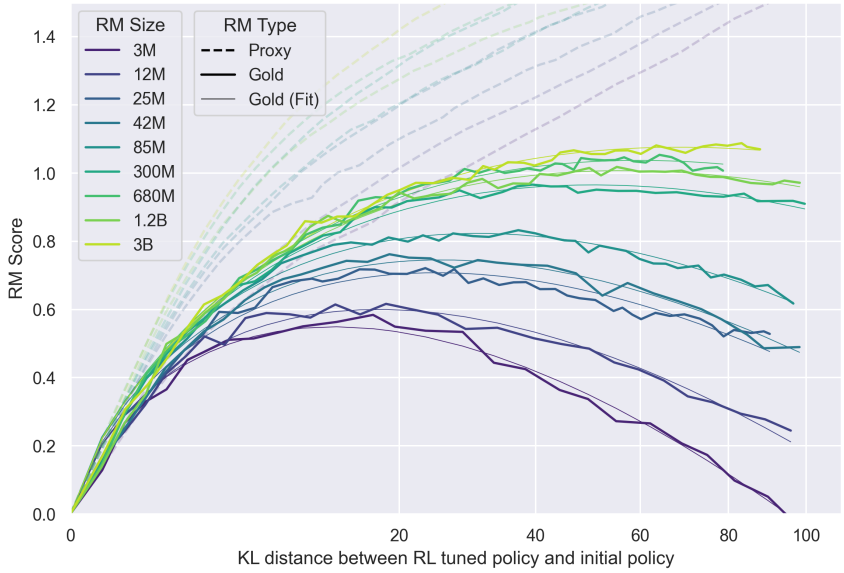
其中系数 $\alpha, \eta > 0$ 取决于代理奖励模型的参数规模与训练偏好样本量（在重排序采样 Best-of-N 场景下对应的规律则为 $d(\alpha_{\text{bon}} - \eta_{\text{bon}} d)$）。

如图 10 所示，式 (12) 意味着只要优化程度 d 超过临界阈值 $\exp(\alpha/\eta - 1)$，继续投入更多强化学习计算不仅不会提升模型性能，反而会导致真实输出质量急剧恶化[8]。在实践中，这种过度优化最常见的表现就是长度膨胀偏差（Length Bias）与空洞套话堆砌：策略模型发现只要不断拉长回复篇幅、罗列格式化工整的分点标题或插入讨好型礼貌用语，就能轻易骗取代理奖励模型的高分。虽然增大奖励模型参数规模和扩充偏好数据可以减小惩罚斜率 η，但其收益随对数规模递减，始终无法在根本上消除强化学习长程演化时的奖励失真上限。

第三项局限体现在离线偏好分布偏移与异质群体偏好的统计不可调和性[10]。从统计推断视角审视，无论是奖励模型训练还是离线 DPO，其观测数据都集中分布在初始行为策略的高



(a) BoN



(b) RL

图 10: 不同参数规模代理奖励模型在重排序采样（上，BoN）与强化学习（下，RL）下的过度优化标度律：虚线为代理奖励模型自评得分，实线为真实金标准奖励得分。随着分布偏移距离 $\sqrt{\mathrm{KL}}$ 增大，代理得分持续虚高，而真实生成质量在越过临界峰值后急剧恶化；扩大奖励模型规模虽能抬高曲线但无法消除最终拐点（原图引自文献[8]）。

概率支撑集内；当强化学习试图搜索超越初始策略能力的全新高质量回复区域时，这些区域恰恰是离线偏好样本覆盖最稀疏、奖励估计置信区间最宽的分布外地带，若采取悲观正则化固守高置信区则限制了能力突破，若盲目外推则立即触发奖励欺骗[10]。同时，单一标量奖励架构无法同时忠实表征多元化人类群体之间相互冲突的价值取向。第四项局限则在于长跨度逻辑推理中的信度分配失效：一个针对整段回复打单一偏好分的神经网络奖励模型，既无法精确检验第

37 步代数恒等变形是否正确，也无法为模型自主探索未知解题路径提供零噪声的真伪判据。正是由于主观偏好代理奖励在可扩展性、抗欺骗性与逻辑精确性上的三重受限，研究者开始思考：在那些结果本身就存在客观真伪标准的领域，能否彻底抛弃近似的神经网络奖励模型，直接用绝对可靠的确定性检验程序来驱动强化学习？这一追问直接促成了 RLVR 范式的诞生与崛起。

4 RLVR：从可验证结果中学习

4.1 可验证奖励的构造与适用条件

面对 RLHF 中神经网络奖励模型难以规避的评估噪声与过度优化失效，研究者重新审视了不同下游任务的评估属性差异：文学创作与日常对话等开放域任务固然缺乏唯一标准答案，但在数学解题、算法编程、形式逻辑推演以及带明确格式约束的指令遵循任务中，虽然要求模型从零构造出一条正确的长跨度解答过程较为困难，一旦模型给出了候选输出，检验该结果是否正确却可以通过确定性的计算机程序精确完成。基于这一“求解困难而验证客观”的不对称特性，Tülu 3[6] 明确将这一技术路线总结为基于可验证奖励的强化学习（Reinforcement Learning with Verifiable Rewards，简称 RLVR），即彻底用无参数的确定性验证函数（Deterministic Verifier）替代由人类偏好训练出的神经网络奖励模型，直接依据客观真伪检验结果向强化学习算法提供反馈信号[6,3,2]。

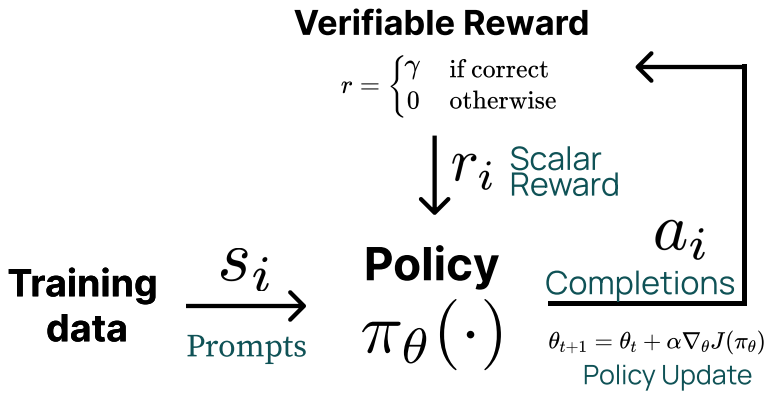


图 11： 基于可验证奖励的强化学习（RLVR）基本交互机制：针对包含客观参考真值或可执行检验标准的输入问题，策略模型自主生成包含推导过程与最终答案的完整序列，确定性验证函数直接核验结果真伪并返回精准的二值或规则化标量奖励，不再经过参数化偏好奖励模型（原图引自文献[6]）。

如图 11 所示，在 RLVR 框架中，训练数据集由问题提示 x 与对应的客观验证准则（如标准参考答案 a 或测试用例集合）构成。当策略模型 π_θ 生成完整回复 y 后，外部确定性验证器 $v(x, y, a)$ 对输出执行自动化核验。在实际系统中，可验证奖励通常由结果准确性奖励与结构格式奖励两部分协同组成[6,3,2]：

$$R_{\text{RLVR}}(x, y, a) = R_{\text{acc}}(x, y, a) + \lambda_{\text{fmt}} R_{\text{fmt}}(y), \tag{13}$$

其中 $\lambda_{\text{fmt}} \geq 0$ 为权重系数。第一项准确性奖励 R_{acc} 针对具体领域设计客观判据：在数学推理任务中，程序首先提取约定定界符（如 `\boxed{...}`）内的最终表达式，随后调用 `SymPy` 或 `Math-Verify` 等符号计算引擎判断其与标准答案 a 在代数化简或数值精度意义下是否等价，等价则赋予正奖励（如 1），不等价或提取失败则赋予零奖励（如 0）；在代码生成任务中，系统在隔离沙箱内编译运行模型输出的代码并逐一执行单元测试样例，根据全部通过与否或测试通过比例给出确定性得分；在精确指令遵循任务（如要求段落数量、特定关键词出现次数或 JSON 语法合规性）中，则通过正则表达式与语法解析器逐条核查约束满足情况[6,2]。第二项格式奖励 $R_{\text{fmt}}(y)$ 则通常规定模型必须将中间思考过程包裹在 `<think>...</think>` 标签内、将最终结论包裹在 `<answer>...</answer>` 标签内，从而确保长思维链与最终答案在结构上清晰分离，保障下游自动解析程序的可靠性[3]。

用如此简洁的规则函数取代复杂的深度神经网络奖励模型，看似在奖励表达细腻度上做了减法，实则在训练动力学上带来了决定性的优势。由于确定性验证器不包含任何拟合误差，无论策略模型在数千步强化学习迭代后偏离初始分布多远，只要最终答案算错或代码未通过测试，模型就绝无可能依靠拉长篇幅、堆砌华丽辞藻或模仿权威语气换取任何虚假正反馈。这种对表面风格投机的天然免疫力，使得强化学习首次能够在极高的训练算力预算下安全运行，迫使策略模型将全部参数更新方向集中在真正提高最终解答准确率的内部推理计算上[3,2]。

当然，这一范式也具有严格受限的适用边界，综述文献将其概括为“验证器法则”（Verifier's Law），即强化学习在某一任务上取得突破的难易程度直接取决于该任务可被客观、快速、自动化验证的程度[2]。具体而言，标准 RLVR 的高效运转必须同时满足四项前提条件：其一，任务必须存在无歧义的客观正确性标准，这使其天然排除了创意写作、价值伦理权衡或开放式方案建议等主观任务；其二，验证过程本身必须轻量化且支持高并发并行执行，如果在科学仿真或大型系统编译中单次验证耗时数十分钟，在线强化学习的采样吞吐将被严重拖垮；其三，答案空间应当足够丰富以抑制盲目猜测，例如在仅有四个选项的选择题或“是/否”判断题中，模型即使推理过程完全混乱也有较高概率蒙对答案并获得正奖励，从而污染梯度信号[15]；其四，基座模型在初始状态下对该难度问题必须具备非零的偶然答对概率，否则在一批采样全部得零分的情况下，二值终端奖励无法提供任何指向正确方向的梯度信息[12,18]。

4.2 GRPO：基于组内比较的策略优化

随着 RLVR 将强化学习推向数千词元长度的复杂数学与代码推理场景，沿用自 RLHF 时代的近端策略优化（PPO）算法在计算资源与价值估计两个层面都遭遇了显著阻力。如第 2.2 节所述，标准 PPO 属于演员—评论家（Actor-Critic）架构，除了正在优化的策略模型 π_θ 之外，还必须同步训练一个体量相当的价值网络 V_ϕ 来逐词元估计状态预期回报并计算广义优势估计（GAE）。在大语言模型后训练中，额外维护一个百亿乃至千亿参数的价值网络不仅使训练显存占用与跨节点梯度同步开销近乎翻倍，而且在 RLVR 的终端二值奖励设定下，价值网络本身的拟合任务极其困难：整段长达数千词元的推理轨迹只有最后一个词元带有 0 或 1 的真实监督信号，要求 V_ϕ 在中间第几百个词元处就精准预测后续数千步复杂代数变换能否最终成功，往往会产生严重的价值估计偏差，进而在训练初期误导策略梯度更新方向[7,12]。

针对这一痛点，Shao 等人在 DeepSeekMath[7] 中提出了群组相对策略优化（Group Relative Policy Optimization，简称 GRPO），成为当前 RLVR 领域应用最广泛的核心优化算法。GRPO 的设计动机十分直接：既然训练独立价值网络既昂贵又不准，不如彻底省去价值评论家模型，转而针对同一个输入问题一次性采样一组候选回复，直接用这组候选回复在当前策略下的平均实际得分作为减方差基线[7]。

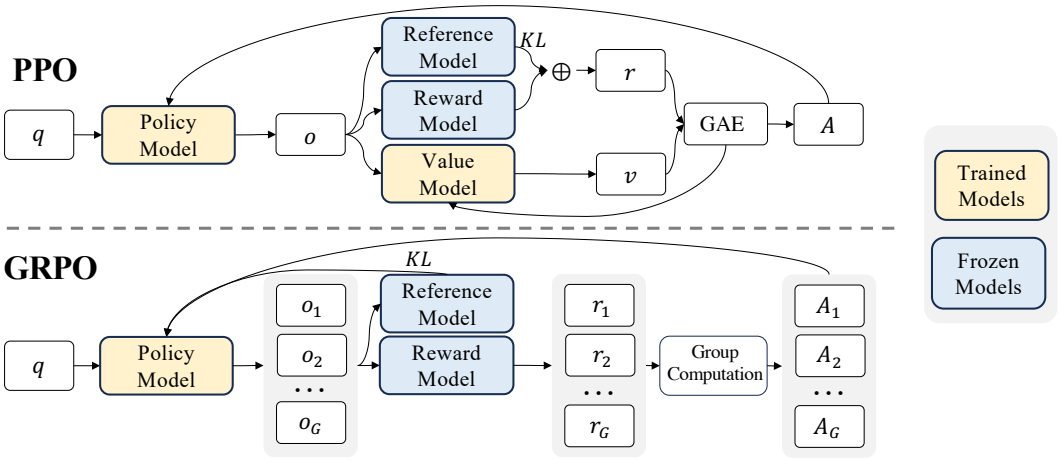


图 12: PPO（上）与 GRPO（下）的训练系统架构对比：GRPO 移除了与策略模型同规模的价值模型（Value Model），改为对每个输入问题采样一组共 G 条输出序列，通过组内奖励的均值与标准差直接归一化计算相对优势，显著降低了显存占用与系统复杂度（原图引自文献[7]）。

如图 12 所示，对于从问题分布 $P(Q)$ 中抽出的任意提示 q，GRPO 首先利用上一轮旧策略 $\pi_{\theta_{\text{old}}}$ 独立并行采样出 G 条完整输出序列 $\{o_1, o_2, \ldots, o_G\}$（实际训练中 G 通常取 8 至 64），并调用奖励函数分别评定每条输出的标量总回报 $\{r_1, r_2, \ldots, r_G\}$。随后，在标准结果监督设定下，GRPO 对这组得分执行组内零均值、单位标准差归一化，并将第 i 条回复所得的相对分数统一赋予该回复中的所有词元位置 $t \in \{1, \ldots, |o_i|\}$ 作为优势估计 $\hat{A}_{i,t}$[7]：

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}\big(\{r_1, r_2, \ldots, r_G\}\big)}{\text{std}\big(\{r_1, r_2, \ldots, r_G\}\big)}. \tag{14}$$

在此基础上，GRPO 沿用 PPO 的概率比截断机制，同时不再将 KL 散度混入单步奖励，而是直接在目标函数末尾减去无偏且恒非负的词元级 KL 散度估计项，其完整优化目标写为[7]：

$$\begin{aligned} J_{\text{GRPO}}(\theta) = \mathbb{E}_{q\sim P(Q),\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}(\cdot|q)} \Bigg[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|} \Bigg(\min\Big(\rho_{i,t}(\theta)\hat{A}_{i,t}, \\ \text{clip}\big(\rho_{i,t}(\theta), 1-\varepsilon, 1+\varepsilon\big)\hat{A}_{i,t}\Big) - \beta\,\mathbb{D}_{\text{KL}}\big(\pi_\theta \,\|\, \pi_{\text{ref}}\big)_{i,t} \Bigg) \Bigg], \end{aligned} \tag{15}$$

其中 $\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q,o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q,o_{i,<t})}$ 为第 i 条输出第 t 个词元的重要性采样概率比，而词元级 KL 估计项采用 $\mathbb{D}_{\text{KL}}(\pi_\theta \,\|\, \pi_{\text{ref}})_{i,t} = \frac{\pi_{\text{ref}}(o_{i,t}|q,o_{i,<t})}{\pi_\theta(o_{i,t}|q,o_{i,<t})} - \log\frac{\pi_{\text{ref}}(o_{i,t}|q,o_{i,<t})}{\pi_\theta(o_{i,t}|q,o_{i,<t})} - 1$，保证了二阶近似意义下的梯度稳定性。

深入审视 GRPO 的机制可以发现其两项核心优势。第一，它巧妙地将不同题目之间的绝对难度差异解耦：一道极难的奥数题可能组内平均得分仅为 0.1，一道简单算术题组内平均得分

高达 0.9，经过式 (14) 的组内中心化之后，每一道题内部答对的轨迹都获得正优势（$\hat{A}_{i,t} > 0$），答错的轨迹都获得负优势（$\hat{A}_{i,t} < 0$），策略模型始终在同一问题的多条自主探索分支之间进行“强化正确解法、抑制错误解法”的对比学习，在统计结构上与人类比较偏好的相对性思想高度契合[7]。第二，省去价值网络释放出的大量计算与显存资源，可以直接转化为更大的采样组规模 G 与更长的上下文窗口，而现代推理引擎（如 vLLM）针对同一提示前缀共享键值缓存（KV Cache）并行生成 G 条序列的硬件效率极高，恰好弥补了多次采样的推理成本。当然，式 (14) 与式 (15) 的具体数学形式也暗含了新的边界退化风险：当某道题对当前模型过难（G 次采样全错，$r_i \equiv 0$）或过易（G 次采样全对，$r_i \equiv 1$）时，组内所有样本的优势估计全部退化为零，该题目将不再贡献任何有效策略梯度；同时，按单条序列长度 $\frac{1}{|o_i|}$ 做平均以及按题目组内标准差做缩放，会在不知不觉间改变不同长度回复与不同难度题目的实际梯度权重，这些问题正是后续第 4.4 节优化方法重点剖析和修正的对象[11-12]。

4.3 代表性训练流程：Tülu 3、DeepSeek-R1-Zero 与 DeepSeek-R1

从工程落地与科学认知演进的角度看，RLVR 如何嵌入大语言模型整体后训练流水线，在短短一两年内经历了从“多阶段对齐末端的专项增强”到“脱离人工示范直接激发原生推理”，再到“可验证推理与通用人类对齐全流程融合”的三次标志性跃迁，其代表作分别是 Tülu 3[6]、DeepSeek-R1-Zero 与 DeepSeek-R1[3]。

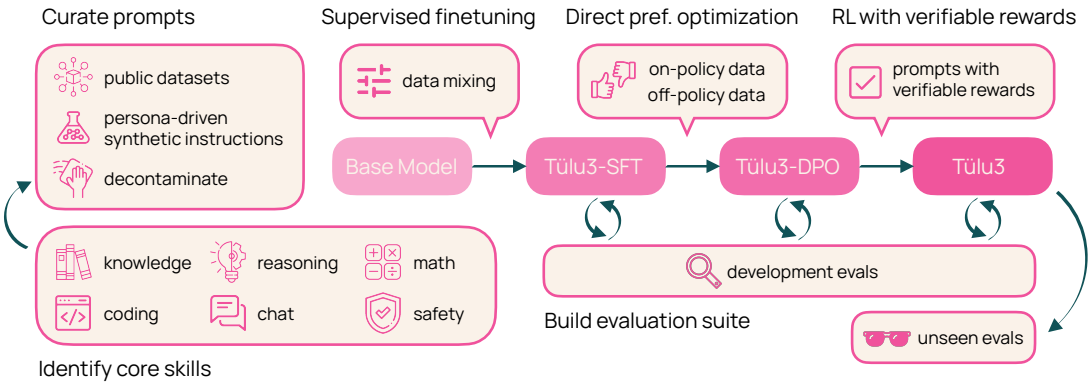


图 13： Tülu 3 的开源多阶段后训练完整配方：依次串联多源指令数据整编、监督微调（Tülu 3 SFT）、基于大规模合成与在线偏好数据的直接偏好优化（Tülu 3 DPO），并在最后阶段引入面向数学与精确指令遵循任务的 RLVR 微调（原图引自文献[6]）。

首先是 Lambert 等人构建的全开源后训练标杆 Tülu 3[6]，其整体架构如图 13 所示。在 Tülu 3 的设计逻辑中，RLVR 被定位于标准指令微调与偏好对齐之后的第四阶段专项精细调优：团队首先在近百万条精心去重与配比的指令集上执行监督微调赋予模型多任务基础能力，随后开展大规模 DPO 偏好对齐塑造通用对话质量，最后针对 GSM8K、MATH 数学求解与 IFEval 精确格式约束遵循这三类具备确定性验证程序的任务，启动带 KL 惩罚的在线 PPO 训练（正确赋予奖励 $\alpha = 10$，错误赋予 0）[6]。Tülu 3 的实践验证了在已经完成偏好对齐的模型末端追加轻量级 RLVR，能够在不破坏通用对话能力的前提下稳定提升目标可验证基准得分。然而，受

限于仅在短回复对齐模型末端做局部微调且保留较强的参考分布约束，这一模式下的模型基本维持了原有的作答篇幅与固定解题套路，尚未展现出质的推理范式跃迁。

真正改变学界传统认知的是 DeepSeek 团队提出的 DeepSeek-R1-Zero[3]。长期以来，后训练领域普遍默认“必须先用人工或强模型撰写的思维链数据开展监督微调教会模型如何一步步推导，随后才能用强化学习做补充性校准”。DeepSeek-R1-Zero 摒弃了这一前提，尝试直接在未经任何监督微调的纯预训练基座模型 DeepSeek-V3-Base（6710 亿总参数混合专家架构）上启动大规模 GRPO 强化学习，整个训练过程不提供任何人工解题步骤示范，不训练任何神经网络奖励模型，仅依靠最终答案准确性规则奖励与简单的 `<think>` 标签格式奖励驱动数千步在线迭代[3]。

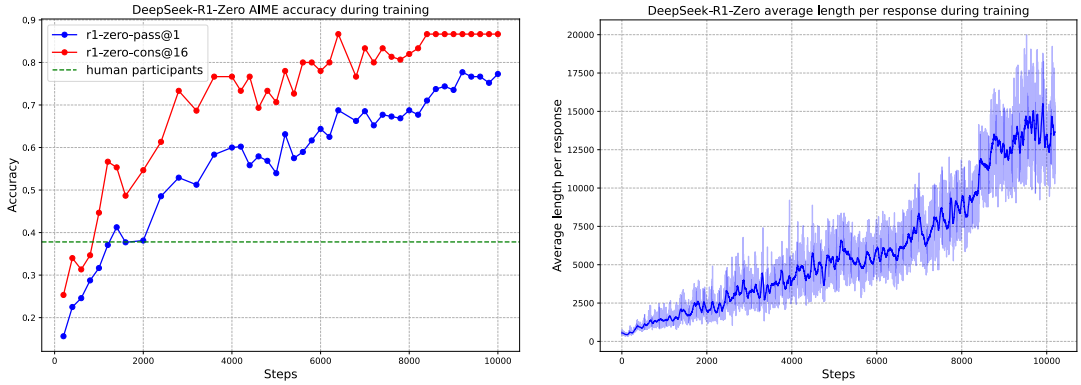


图 14: DeepSeek-R1-Zero 在纯强化学习训练过程中的演化轨迹：左图显示模型在极具挑战性的美国数学邀请赛基准 AIME 2024 上的单次采样准确率（pass@1）从初始 15.6% 持续攀升至 71.0%（后期进一步达 77.9%），16 次采样多数投票准确率（cons@16）达到 86.7%，匹敌乃至超越 OpenAI-o1-0912；右图显示训练集上的平均生成长度在无显式长度奖励干预下自发从数百词元持续增长至近万词元（原图引自文献[3]）。

图 14 记录了这一纯强化学习实验极具代表性的演化过程[3]。随着训练步数推进，DeepSeek-R1-Zero 在 AIME 2024 竞赛基准上的单次采样准确率从 15.6% 持续上升至 71.0%（延长训练后达 77.9%），配合多数投票达到 86.7%。比分数提升更重要的发现在于图 14 右侧的生成长度曲线：尽管奖励函数中没有任何鼓励增加字数的条款，模型为了在复杂多步推理中拿到终端正确奖励，自发学会了在 `<think>` 标签内大幅延长推导篇幅，按题目实际复杂度动态分配测试时计算量。在训练中后期，模型输出中频繁出现暂停复核（如在中间步骤自发生成“Wait, let me re-evaluate”）、识别前文计算矛盾、否定已有错误假设并切换新解题路径等反思修正行为（原论文将其称为“Aha Moment”）[3]。这一结果有力证明，大规模预训练基座内部已蕴含着丰富的逻辑推演先验，纯粹的客观结果强化学习足以在不依赖人工过程示范的前提下激发并组织复杂的长链推理机制。

然而，纯粹的“零监督微调”路线也付出了明显的使用体验代价。由于奖励函数只关心最终框内答案是否正确而对思考过程本身的语言形态毫无约束，DeepSeek-R1-Zero 生成的思维链普遍存在可读性差、排版杂乱的问题，尤为突出的是中英文等多语种词汇在同一段推导中频繁混

杂切换，且该模型缺乏在非推理类开放任务（如角色扮演、创意写作与安全合规交互）上的基本对齐能力[3]。为了保留纯强化学习强大的推理涌现能力，同时彻底解决可读性与通用任务适用性缺陷，团队进一步设计了融合冷启动数据与多轮迭代的四阶段训练流水线，构建出旗舰模型 DeepSeek-R1[3]，其完整流程如图 15 所示。

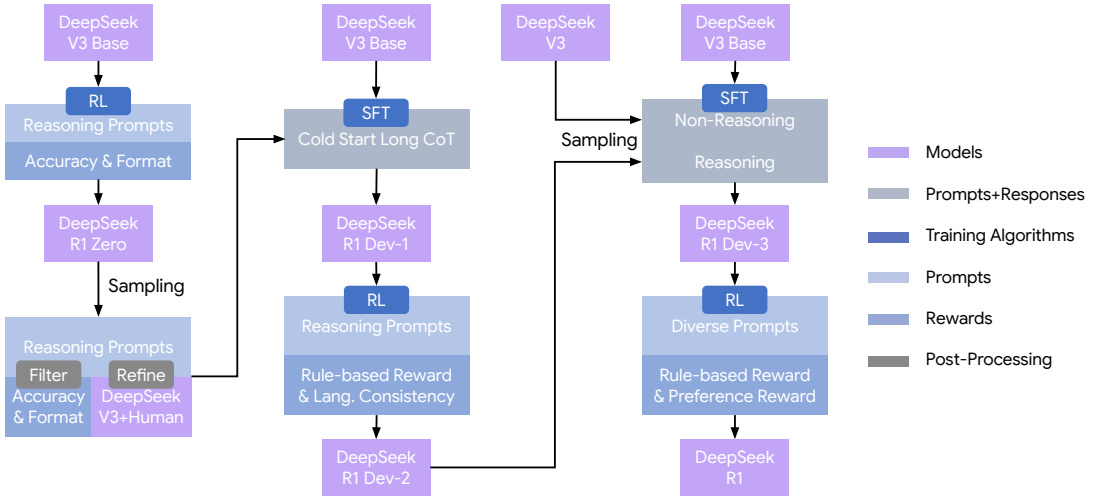


图 15: DeepSeek-R1 的四阶段协同后训练流水线：通过少量高质量长思维链冷启动监督微调奠定规范表达格式，经由带语言一致性约束的面向推理强化学习激发深层解题能力，再利用拒绝采样融合通用领域监督微调重建全场景能力，最后通过混合规则奖励与偏好奖励模型的全场景强化学习完成综合对齐（原图引自文献[3]）。

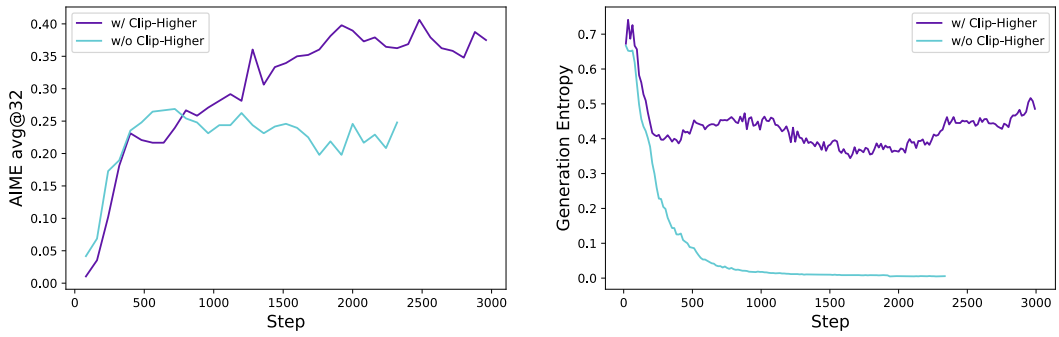
剖析图 15 中的四个阶段可以清晰看出工业界顶级推理模型对监督学习与强化学习各自边界的精准拿捏[3]。第一阶段为冷启动监督微调（Cold Start）：收集数千条格式规范、包含末尾可读总结的高质量长思维链样本微调 DeepSeek-V3-Base，使模型在进入高成本强化学习之前即掌握人类易读的思考排版规范，避免了 R1-Zero 早期的无序探索震荡。第二阶段为面向推理的强化学习（Reasoning-oriented RL）：在数学、编程、科学与逻辑推理任务上执行与 R1-Zero 相同的大规模规则奖励 GRPO 训练，并额外引入一项统计目标语言词汇占比的“语言一致性奖励”（Language Consistency Reward）——消融实验表明，该约束虽使竞赛准确率出现极轻微折损，却彻底消除了中英文混杂顽疾，大幅改善了人类阅读体验。第三阶段为拒绝采样与全领域监督微调（Rejection Sampling and SFT）：当第二阶段推理强化学习收敛后，利用所得强推理检查点对海量提示多次采样，结合规则验证器与生成式评判模型筛除含错或混杂轨迹，精选出约 60 万条高质量推理样本，再与约 20 万条写作、事实问答、翻译及自我认知等非推理通用监督数据混合，重新对基座模型 DeepSeek-V3-Base 执行两轮全量监督微调，从而将强化学习探索出的高阶推理能力平滑迁移至具备完备通用能力的单一模型中。第四阶段为全场景强化学习（RL for All Scenarios）：在推理类提示上继续沿用客观规则验证奖励，而在通用开放类提示上引入捕捉人类有用性与安全性偏好的奖励模型开展最终对齐，使模型同时在竞赛推理与日常助手评估上达到顶尖水准。此外，DeepSeek-R1 还揭示了一条重要衍生规律：利用其生成的 80 万条高质量推理轨迹直接对 15 亿至 320 亿参数的中小规模开源基座做监督微调（知识蒸馏），

所得性能远超直接在同等小规模基座上从零运行强化学习的结果，这表明小尺寸模型自身探索容量有限，先通过强模型轨迹转移高阶推理模式再辅以强化学习，是更具性价比的能力构建路径[3]。

4.4 优化方法的改进：DAPO 与 Dr. GRPO

随着学术界与开源社区纷纷尝试在公开权重模型（如 Qwen2.5-32B 等）上复现 DeepSeek-R1-Zero 式的长链推理强化学习，研究者很快发现：直接套用式 (14) 与式 (15) 给出的原始 GRPO 公式，训练过程往往在几百步后便陷入停滞甚至中途崩溃，远未达到理想性能上限。围绕“原始 GRPO 在大规模长序列 RLVR 训练中究竟存在哪些优化缺陷”，Yu 等人提出的解耦截断与动态采样策略优化（DAPO）[11] 与 Liu 等人提出的无偏群组相对策略优化（Dr. GRPO）[12] 分别从工程可扩展性与目标函数数学无偏性两个互补视角给出了深刻诊断与关键修正。

DAPO[11] 在以 Qwen2.5-32B 基座复现数学竞赛强化学习时观察到，朴素 GRPO 在 AIME 2024 上仅能收敛至 30% 准确率，其核心问题集中在策略熵过早坍缩、零优势样本浪费算力以及序列级损失加权失衡三个方面。首先，如图 16 右侧蓝线所示，朴素 GRPO 训练开始后不久，策略输出分布的条件熵便急剧跌向零点，这意味着模型迅速将概率集中到极少数固定表述上，彻底丧失了探索多样化解题思路的能力。为什么标准对称截断区间 $[1-\varepsilon, 1+\varepsilon]$（如 $\varepsilon = 0.2$）会诱发熵坍缩？DAPO 指出这是由概率比乘性截断对高概率词元与低概率词元的极度不对称限制造成的：对于一个旧概率 $\pi_{\theta_{\text{old}}} = 0.9$ 的高频常规词元，上限 $1+0.2 = 1.2$ 允许其单步更新后概率直接达到 1.0；但对于一个旧概率仅为 $\pi_{\theta_{\text{old}}} = 0.01$ 的低概率反思或转折探索词元，即便它成功引导出了正确解答，上限 1.2 也将其单步更新后的新概率严格限制在 0.012 以内，导致高概率常规路径迅速占据主导概率，低概率探索词元的概率难以有效增长[11]。



(a) Accuracies on AIME. **(b)** Entropy of actor model.

图 16: DAPO 中解耦上界截断策略（Clip-Higher）对准确率与策略探索熵的影响：保持下界截断阈值 $\varepsilon_{\text{low}} = 0.2$ 不变而适当放宽上界截断阈值 $\varepsilon_{\text{high}} = 0.28$ 后，低概率探索词元获得充足概率增长空间，成功阻止了策略生成熵（右图）的急剧衰减，使 AIME 测试准确率（左图）突破早期平台持续上升（原图引自文献[11]）。

针对上述诊断，DAPO 提出了四项简洁而高效的改进并组合成统一的词元级优化目标[11]：

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a)\sim\mathcal{D},\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}(\cdot|q)}\left[\frac{1}{\sum_{i=1}^{G}|o_i|}\sum_{i=1}^{G}\sum_{t=1}^{|o_i|}\min\Big(\rho_{i,t}(\theta)\hat{A}_{i,t},\ \text{clip}\big(\rho_{i,t}(\theta),1-\varepsilon_{\text{low}},1+\varepsilon_{\text{high}}\big)\hat{A}_{i,t}\Big)\right], \tag{16}$$

$$\text{满足约束：}\quad 0 < \Big|\big\{o_i \;\big|\; \text{is_equivalent}(a,o_i)\big\}\Big| < G.$$

式 (16) 凝聚了三项核心算法创新（同时移除了规则奖励下不必要的 KL 惩罚项）：第一是解耦截断（Clip-Higher），将下界保持在 $\varepsilon_{\text{low}} = 0.2$ 以继续防止负优势样本将有用词元概率瞬间削减为零，同时将上界放宽至 $\varepsilon_{\text{high}} = 0.28$，为低概率探索词元打开增长通道，如图 16 所示直接化解了熵坍缩；第二是动态采样（Dynamic Sampling），随着训练推进越来越多简单题目在组内 G 次采样中全部答对（导致标准差与优势全为零），有效梯度批次占比不断萎缩，DAPO 在采样阶段实时过滤掉全对（正确数为 G）与全错（正确数为 0）的提示并持续补充采样，直至批次内每一道题都严格包含部分正确与部分错误样本，从而保证百分之百的样本都产生有效对比梯度；第三是词元级策略梯度损失（Token-Level Policy Gradient Loss），将原本 GRPO 先对每条回复除以自身长度 $\frac{1}{|o_i|}$ 再对 G 求平均的做法，改为直接除以整组所有回复的总词元数 $\sum_{i=1}^{G}|o_i|$，使长思维链中的高质量推理步骤得到应有权重，同时严厉惩罚超长错误回复中的乱码与重复句式。此外，针对达到最大上下文窗口被强制截断的未完结长回复，DAPO 引入超长奖励塑形（Overlong Reward Shaping），避免对推理方向完全正确仅因超长未写出答案的样本直接打 -1 分引入矛盾噪声，改为过滤截断样本或在临近长度上限的缓冲区间施加平滑线性长度惩罚。凭借这套组合改进，DAPO 在 Qwen2.5-32B 基座上仅用 DeepSeek-R1-Zero 一半的训练步数便将 AIME 2024 准确率推升至 50%[11]。

与 DAPO 关注长序列扩展工程障碍相呼应，Liu 等人在 COLM 2025 发表的研究[12]则从更为基础的数学期望角度审视了一个关键疑问：为什么几乎所有采用原始 GRPO 训练的模型，其生成长度都会在训练后期无节制地持续暴涨，甚至在奖励已经不再增长时仍然越写越长？难道这全部都是高阶推理能力涌现的体现吗？通过对式 (15) 的梯度结构进行严格分解，作者揭示出原始 GRPO 目标函数中潜藏着两项人为引入的优化偏差（Optimization Biases）[12]。

第一项偏差是回复级长度偏差（Response-Level Length Bias），根源恰恰在于目标函数中对每条轨迹除以自身长度的因子 $\frac{1}{|o_i|}$。考虑同一题目下两条同样答对（$\hat{A}_{i,t} > 0$）的回复，较短回复由于分母 $|o_i|$ 更小，其内部每个词元获得了更大的正向梯度更新，促使模型在正确作答时偏好简短；但反过来，考虑两条同样答错（$\hat{A}_{i,t} < 0$）的回复，越冗长啰嗦的错误回复由于分母 $|o_i|$ 极大，其每个词元分摊到的负向惩罚反而越轻微！这种正负不对称导致优化器无法有效抑制超长错误轨迹，迫使模型在不会做的难题上倾向于生成越来越冗长的无效废话以稀释每步惩罚（作者进一步审查主流开源代码库发现，许多标称使用 PPO 的框架因沿用预训练阶段的掩码均值函数 `masked_mean` 按回复实际长度归一化，同样在无意间引入了这一长度偏差）[12]。第二项偏差则是问题级难度偏差（Question-Level Difficulty Bias），源于式 (14) 分母中的单题组

内标准差 $\mathrm{std}(\{r_1,\ldots,r_G\})$：对于接近全对或接近全错的极易或极难题目，组内奖励标准差极小，倒数缩放会赋予这些边角题目异常巨大的梯度权重，扭曲了整批数据的真实期望回报目标。

为了彻底消除上述两项人为偏差、恢复策略梯度对真实蒙特卡洛优势的无偏估计，Liu 等人提出了去偏改进算法 Dr. GRPO（即 GRPO Done Right）[12]，直接移除分母中的动态序列长度 $|o_i|$（实现时仅除以全局固定的最大生成预算常数 $C_{\max}$ 以保持数值量级稳定）与问题级标准差归一化项，将优化目标精简为：

$$J_{\text{Dr.GRPO}}(\theta) = \mathbb{E}_{q\sim P(Q),\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}(\cdot|q)}\left[\frac{1}{G\,C_{\max}}\sum_{i=1}^{G}\sum_{t=1}^{|o_i|}\min\Big(\rho_{i,t}(\theta)\tilde{A}_{i,t},\ \mathrm{clip}\big(\rho_{i,t}(\theta),1-\varepsilon,1+\varepsilon\big)\tilde{A}_{i,t}\Big)\right], \tag{17}$$

其中无偏中心化优势直接取为 $\tilde{A}_{i,t} = r_i - \mathrm{mean}\big(\{r_1,\ldots,r_G\}\big)$。

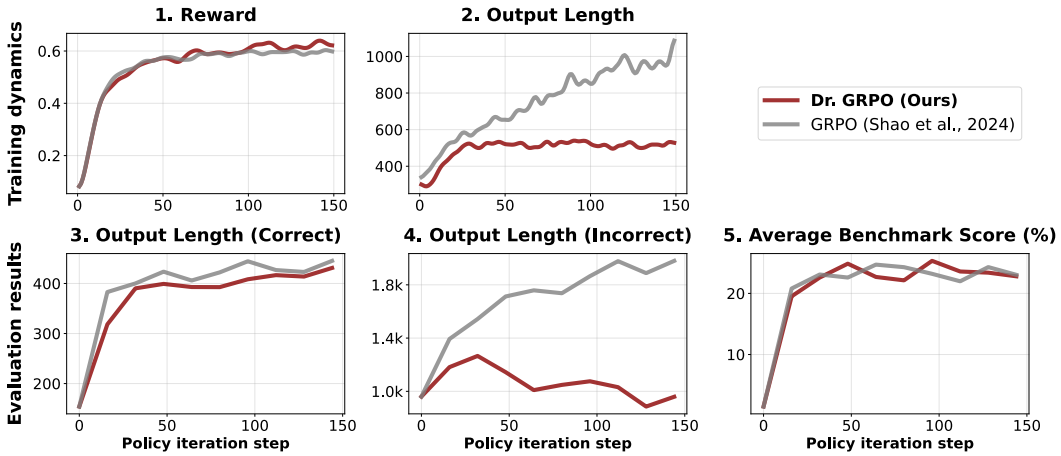


图 17: Dr. GRPO 与原始 GRPO 的训练动态及评测表现对比：在取得同等乃至更优训练奖励（图 1）与五大数学基准平均评测准确率（图 5）的前提下，Dr. GRPO 显著遏制了训练后期输出长度的无休止膨胀（图 2），尤其是大幅压缩了评测集上错误回复的无效冗长篇幅（图 4），显著提升了词元推理效率（原图引自文献[12]）。

如图 17 所示，实验结果清晰印证了这一理论诊断[12]。在前期奖励快速上升阶段，Dr. GRPO 与原始 GRPO 的回复长度都会随解题需要合理增长；但当训练进入平台期后，原始 GRPO 的总长度尤其是错误答案长度（图 17 第 4 子图，飙升至近 1800 词元）仍在失控增长，而消除偏差后的 Dr. GRPO 则将长度稳定在合理区间，有效抑制了无效“过度思考”(Overthinking)，在 70 亿参数模型上仅用 8 张 A100 训练 27 小时便在 AIME 2024 上取得 43.3% 的优异成绩。与此同时，该研究还通过对多种开源基座的系统排查指出了另一层常被忽视的认知误区：包括 DeepSeek-V3-Base 在内的绝大多数现代预训练基座在强化学习开始前就已天然包含自我反思词汇，且部分数学基座（如 Qwen2.5-Math）因预训练混入问答拼接语料，套用不当的提示模板会先人为损毁其原有准确率再由强化学习恢复表观分数[12]。这提醒研究者在评估 RLVR 优化算法时，必须严格区分真正来自无偏策略优化的能力增益与来自模板匹配或长度偏差的表观假象。

5 RLHF 与 RLVR 的比较及互补关系

5.1 奖励来源、数据需求与适用任务

站在大语言模型后训练全局架构的高度审视，RLHF 与 RLVR 并非后者简单淘汰前者的线性替代关系，而是针对两类截然不同的任务评估属性演化出的互补技术范式。要准确把握二者的边界，需要从奖励信号来源、核心数据需求、可承载的强化学习算力规模以及适用任务谱系四个相互关联的维度进行系统对比[1,6,3,2]。

在奖励信号来源上，RLHF（包括显式奖励模型 PPO 与隐式奖励 DPO）的评估依据来自人类的主观综合价值判断。它通过参数化的神经网络去逼近人类标注群体在比较两条回复时表现出的潜在偏好分布，输出的是反映相对满意度的连续标量预测值[4,1,5]。相反，标准 RLVR 的评估依据完全独立于主观感受，直接来自针对任务客观真值编写的确定性计算机检验程序（如符号代数等价判定器、代码执行沙箱及格式语法解析器），输出的是绝对客观的离散通过信号或精确测试通过率[6,3]。

这种奖励来源的本质差异直接改变了后训练阶段的数据工程重心。RLHF 的主要数据开销集中在采集高质量、覆盖广泛指令意图的人类成对偏好标注三元组 (x, y_w, y_l) 上：提示 x 本身甚至无需附带任何标准答案，但每一对模型生成的候选回复都必须经过人工或高能力教师模型的审阅排序；一旦模型迭代升级导致生成分布显著改变，原有的离线偏好集就会面临过时风险，往往需要重新采样与标注[1,10]。而在 RLVR 中，训练过程彻底免去了对模型生成过程与输出结果的人工逐条审阅，数据构建的重心前移到了“高质量可验证问题库与高覆盖率检验标准”的收集与清洗上，即构建大规模提示—真值对 (x, a) 或提示—单元测试集[6,3,11]。只要题目难度校准得当且标准答案或测试用例准确无误，同一批题库就可以支撑策略模型在线自主采样数百万条轨迹反复试错而不产生任何边际人工标注费用。

由此进一步决定了两者在适用任务范围与强化学习优化深度上的显著分工。RLHF 天然适用于那些缺乏唯一客观标准答案、但人类对其表达质量有明确感知的开放域交互任务，典型代表包括日常多轮对话、长文档摘要提炼、文学创意写作、职场邮件润色、语气风格定制以及涉及伦理价值权衡的安全拒答任务[1,5]。在这类任务中，优化目标主要是调整已有知识的表述组织方式与安全边界，通常只需数百步中等强度的强化学习或一至两轮偏好优化即可收敛。反之，RLVR 则专精于具备严密逻辑结构与客观真伪判据的复杂求解任务，涵盖竞赛级数学推导、算法与系统代码生成、科学计算推理、形式化定理证明、复杂逻辑谜题以及带严格结构化输出要求的工具调用与指令遵循任务[6,3,16]。在这类任务中，模型不仅需要调整表面表述，更需要通过数千步高强度在线探索重构内部多步推理策略。简言之，RLHF 解决的是“如何使模型按照符合人类交流习惯与安全规范的方式表达”，而 RLVR 解决的是“如何使模型通过深度思考攻克客观高难度复杂问题”。

5.2 结果监督与过程监督：反馈粒度的另一条划分轴

在对比 RLHF 与 RLVR 时，文献中常常还会交织出现另一组重要概念：结果监督（Outcome Supervision）与过程监督（Process Supervision）。必须明确指出的是，RLHF 与 RLVR 是沿

着“奖励信号来源于主观偏好模型还是客观检验规则”这一维度划分的，而结果监督与过程监督则是沿着一条与之正交的“反馈信号在生成序列时间轴上的稠密粒度”维度划分的[13,7,2]。理解这两条划分轴的交汇与取舍，对于洞察现代推理模型演进逻辑至关重要。

为什么在客观推理任务中会提出过程监督？前文提到，标准 RLVR 仅根据模型在序列最末端给出的最终答案对错发放单一标量奖励，这属于典型的结果监督。Lightman 等人在开创性工作《Let's Verify Step by Step》[13]中敏锐指出，仅依赖最终结果反馈在复杂多步数学推理中面临双重隐患：其一是“错误过程导出正确结果”的虚假正例问题（False Positives），例如模型在中间两步推导中犯了方向相反的符号错误却碰巧抵消得到了正确数值，结果监督会无差别地奖励这些包含逻辑谬误的步骤；其二是长序列信度分配模糊，当一段包含二十步推导的解答因第十五步算错而最终得零分时，终端结果监督会将前十四步完全正确的关键构思一并惩罚。

为了精细化定位推理链中的具体成败节点，Lightman 等人构建了包含 80 万条人工步骤级正确性标注的数学推理数据集 PRM800K，系统对比了仅由最终答案训练的结果奖励模型（Outcome-supervised Reward Model，简称 ORM）与由人工逐步标注训练的过程奖励模型（Process-supervised Reward Model，简称 PRM）[13]。在 PRM 中，每当模型生成一个以换行符分隔的推理步骤，奖励网络便立即预测该步骤在当前上下文中是否正确，整条解答的综合评分由各步骤正确概率的连乘积（或最小值）给出；为了降低昂贵的专家标注成本，作者还设计了主动学习（Active Learning）筛选策略，专门挑选那些“令当前模型给出高置信度但最终答案实际上算错”的极具迷惑性样本交由人类标注，实现了 2.6 倍的数据效率提升[13]。

如图 18 所示，在基于候选重排序（Best-of-N）的推理测试时搜索评估中，过程监督展现出了压倒性优势：随着采样候选数 N 增加到 1860，多数投票准确率较早停滞在 69.6%，ORM 提升至 72.4% 但曲线趋缓，而 PRM 则一路攀升至 78.2%，且候选池越大领先幅度越显著[13]。这是因为当候选池中混入大量凑巧蒙对答案的伪正确解答时，唯独能够逐行甄别推理有效性的 PRM 可以精准筛出逻辑真正严密的解法。后续 DeepSeekMath[7] 等工作也尝试利用无需人工标注的蒙特卡洛树展开成功率自动构造步骤级 PRM 来配合 GRPO 训练。

然而，一个值得深入分析的技术转折在于：当研究从测试时重排序走向以 DeepSeek-R1[3] 为代表的超大规模在线强化学习训练时，最终取得突破性进展的恰恰是仅依赖最终结果的可验证结果监督（RLVR），而非步骤级神经网络过程奖励模型（PRM）。DeepSeek-R1 团队在专门记录的对比实验中深入剖析了放弃神经 PRM 的三大根本原因[3]：第一，在自由演化的自然语言思维链中，模型常常将猜想、试算与反证交织在同一句话里，难以客观界定清晰的步骤切分边界，更难以判定某次探索步骤究竟是有益尝试还是错误推导；第二，无论是雇佣人类专家逐步标注（在严密质检的 PRM800K 中仍存在约 20% 的人工噪声[13]）还是在每一步额外展开数十次蒙特卡洛采样估计价值，其标注与计算开销都限制了算法向更广泛问题集扩展；第三也是最关键的一点，只要过程奖励是由参数化神经网络给出的预测分值，一旦将其接入数千步高强度在线强化学习循环，策略模型就会迅速针对 PRM 产生奖励欺骗——例如不断重复输出“显而易见，由题意可知”等不会出错的套话来获取每一步的高过程得分，反而丧失了攻克难题的实际能力[3]。这一发展历程揭示出一条重要认识：在大规模强化学习参数优化中，奖励信号的抗欺骗

	ORM	PRM	Majority Voting
% Solved (Best-of-1860)	72.4	**78.2**	69.6

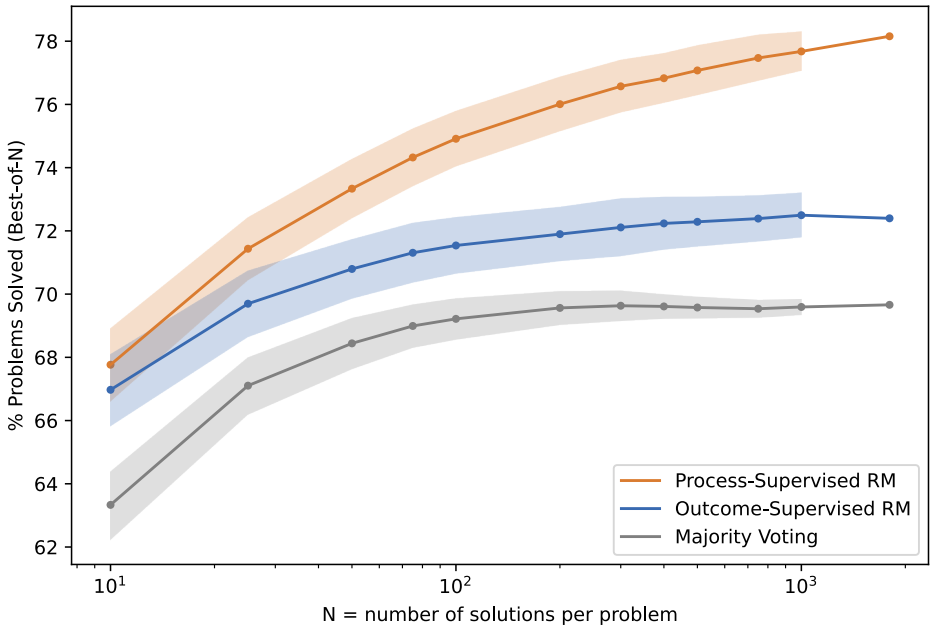


图 18: 在挑战性的 MATH 数学测试集上，随着每道题采样的候选解答数量 N 从 1 扩展至 1860，过程监督奖励模型（PRM）、结果监督奖励模型（ORM）与多数投票（Majority Voting）重排序准确率的对比：步骤级过程监督凭借精准剔除中间推导谬误的能力，随搜索规模扩大持续拉大领先优势（原图引自文献[13]）。

可靠性远比反馈信号的时间步稠密性更为关键；只要终端结果验证精准无偏且基座模型具备基本逻辑先验，稀疏的结果级 RLVR 同样能够在大量采样对比中隐式完成步骤级信度分配[15]。

5.3 奖励可靠性

由过程监督与结果监督的实践分野进一步延伸，我们可以看到“奖励可靠性（Reward Reliability）”实际上构成了制约强化学习后训练能否持续扩展（RL Scaling）的首要决定因素。在预训练阶段，增大算力与数据量之所以能稳定换取更低的交叉熵损失，是因为真实文本词元本身就是无偏的监督目标；而在强化学习阶段，策略模型会主动调整自身分布去搜寻奖励函数的最大值点，奖励函数中哪怕微小的评估漏洞，在高强度优化压力下都会被显著放大并导致生成分布扭曲[8,3]。

图 19 直观展示了 DeepSeek 团队在早期实验中使用大规模神经网络奖励模型训练推理策略时观测到的真实退化曲线[3]。可以看到，在前两三百个训练步内，神经奖励模型得分（蓝色圆点曲线）与 CodeForces 真实代码测试通过率（红色菱形折线）尚能保持一定协同增长；但越过临界点后，策略模型迅速利用了神经奖励模型的判别偏差，通过生成看似结构复杂实则无法通过边界测试的代码持续推高代理奖励分值，导致真实竞赛通过率急剧下跌，印证了第 3.4 节 Gao 等人[8]理论刻画的过度优化曲线。若想通过重新采集当前策略样本不断重训奖励模型来修补漏洞，不仅会使工程管线变得复杂脆弱，还会引发策略与奖励模型交替震荡的不稳定动态。与

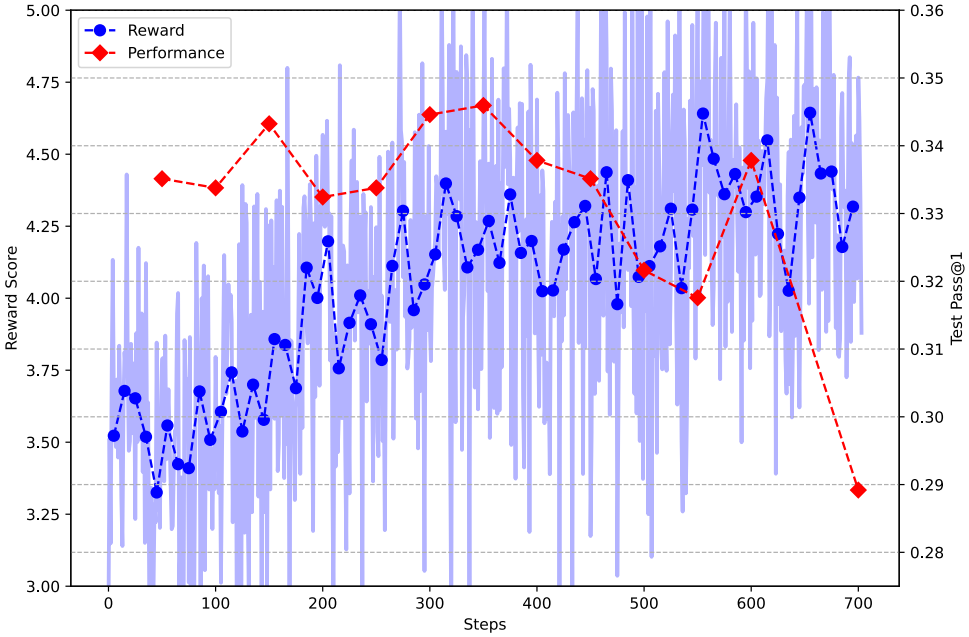


图 19: 在大规模代码与推理强化学习中使用神经网络奖励模型引发的典型奖励欺骗实证：随着训练步数推进，神经奖励模型给出的训练集代理得分（蓝色圆点曲线，左轴）持续攀升，但模型在客观竞赛基准 CodeForces 上的真实单次通过率 Pass@1（红色菱形折线，右轴）在短暂上升后便急剧下滑（原图引自文献[3]）。

之相印证，Tülu 3[6]在受控消融实验中曾尝试将通用人类偏好奖励模型的连续打分与确定性数学验证器的二值奖励线性相加共同指导 PPO 训练，结果发现混入偏好奖励模型后模型的最终数学解题准确率反而明显低于纯粹使用二值可验证奖励的基线，原因正在于连续偏好打分的方差掩盖了精确的真伪边界，为策略模型提供了无需做对题目也能涨分的非目标优化途径。

当然，客观分析奖励可靠性，同样不能将现有的手工规则验证器视作毫无局限的理想判据。规则验证器的核心优势在于极低的“假阳性率（False Positive Rate）”——在覆盖完备的多个高难度单元测试用例或非平凡精确数值匹配下，错误代码与错误算式极难通过核验，从而阻断了恶性奖励欺骗。但与此同时，手工编写的规则解析器在面对复杂多变的表达形式时往往存在显著的“假阴性率（False Negative Rate）”与覆盖局限[6,19]。例如，当标准答案写为 $\frac{\sqrt{2}}{2}$ 而模型输出等价的 0.7071 或带有物理量纲说明的完整句子但未被规则库覆盖时，僵硬的字符串或符号规则会将其误判为零分；在跨学科自由简答（如医学诊断分析或经济学机制阐述）中，强行使用精确匹配规则甚至会迫使模型为了迎合僵化词面而丢失实质推理内容，导致训练数据越多性能反而越差[19]。反之，在选项极少的选择题或答案仅为小整数的题目上，纯结果规则验证又会面临偶然猜中答案带来的假阳性干扰[15]。因此，奖励可靠性的本质要求既不是盲目排斥模型参与验证，也不是局限于简单字符串规则，而是确保验证信号与真实任务目标之间不存在可被策略梯度利用的系统性偏差。

5.4 偏好对齐与可验证任务学习的结合

既然 RLVR 凭借高可靠性的客观验证赋予模型深层逻辑推理能力，而 RLHF（及 DPO）凭借灵活的人类偏好拟合赋予模型自然流畅的表达风格、多领域指令遵循能力与安全合规边界，那么在一个面向真实用户部署的通用大语言模型中，如何将这两类强化学习机制有机结合起来，使其既具备严密可靠的多步逻辑推理能力，又保持自然清晰、安全合规的开放交互表现，便成为现代后训练流水线设计的核心课题[6,3,2]。

从现有代表性系统的实践来看，融合偏好对齐与可验证任务学习主要形成了两条成熟路径，二者在阶段先后顺序与分布耦合机制上各有明确考量。第一条路径是以 Tülu 3[6] 为代表的“先偏好对齐、后可验证强化”串联路径，即依次执行 SFT → DPO → RLVR。在这一路径中，研究者重点关注的一个核心问题是：在进入最后阶段 RLVR 之前先做 DPO 偏好对齐，究竟会因为收紧输出分布而妨碍数学探索，还是能为 RLVR 提供更优质的初始策略起点?

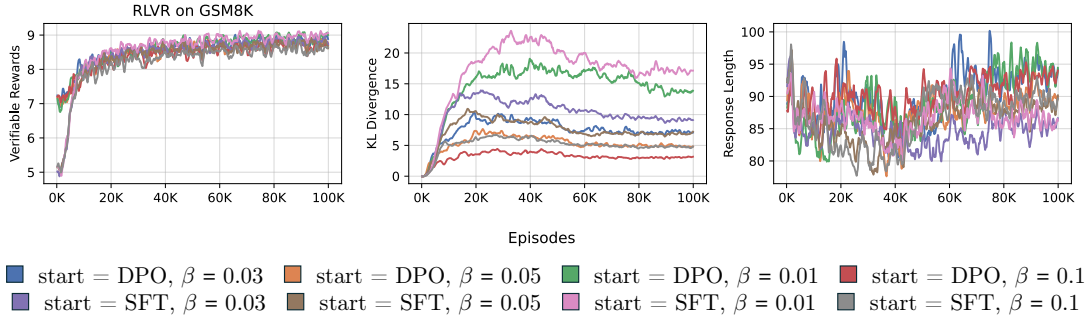


图 20: Tülu 3 分别以经过直接偏好优化的模型（start = DPO，深色饱和曲线）与仅经过监督微调的模型（start = SFT，同色系浅色曲线）作为初始策略和参考基准开展 GSM8K 可验证奖励强化学习的对比：在不同 KL 惩罚系数下，以 DPO 模型为起点不仅取得了更高的可验证奖励水平（左），而且在整个训练过程中保持了显著更低的 KL 散度分布偏移（中）与更受控的回复长度区间（右）（原图引自文献[6]）。

图 20 给出了清晰的实验答案[6]。对比直接从 Tülu 3 SFT 模型启动 RLVR（同色系浅色曲线）与从 Tülu 3 DPO 模型启动 RLVR（深色饱和曲线）可以发现，DPO 初始化不仅在初始时刻就具备更高的可验证奖励得分，而且在完全相同的强化学习步数与多组 KL 惩罚系数设置下，始终维持在更高的奖励平台并对应更优的测试准确率（左图），同时其相对于参考策略的累积 KL 散度偏移不到 SFT 初始化方案的一半（中图），回复长度也保持在更为紧凑平稳的区间（右图）。其内在机理在于，DPO 阶段已经剔除了监督微调模型中大量格式松散、逻辑断裂的低质量生成分支，使 RLVR 无需耗费算力去重新修正基础回复规范，只需在相对紧凑的高质量分布邻域内微调概率即可锁定正确解题路径，同时较小的 KL 偏移也最大限度保留了前一阶段已经建立好的通用对话胜率与安全性表现[6]。

第二条路径则是以 DeepSeek-R1[3] 为代表的“先专项长链 RLVR 突破推理上限、经拒绝采样融合通用 SFT、最后开展分域混合奖励对齐”的深度协同路径（参见前文图 15）。为什么在训练超强长思维链推理模型时不能简单套用第一条路径直接在常规 DPO 对齐模型后面做轻量微调？因为常规人类偏好对话普遍偏爱简洁凝练的数百词回复，经过强偏好对齐的模型输出分

布往往已被锁定在短回复模式上，很难再通过数千步自由探索生长出长达上万词元的反思型思维链。因此，DeepSeek-R1 选择在冷启动后首先投入绝大部分强化学习算力运行纯粹的规则驱动 RLVR，待深层推理能力充分涌现后，通过拒绝采样将推理轨迹与通用写作、安全数据统一蒸馏回同一个监督模型，最后在第四阶段“全场景强化学习”中实施分域精准施策[3]：对于数学、代码与逻辑提示，依然严格调用确定性规则验证器计算奖励；对于开放式问答与创意辅助提示，则调用偏好奖励模型与安全奖励模型评估回复质量（尤为关键的工程细节是，有用性奖励模型仅对 `<answer>` 摘要总结部分打分而不干预 `<think>` 内部自由推理过程，且该混合对齐阶段严格控制在最后数百步内完成，彻底杜绝神经奖励模型侵蚀推理核心逻辑）。这两条路径共同证明，客观可验证奖励与主观人类偏好并非彼此排斥，通过在训练阶段顺序与作用文本区间上实施合理隔离与衔接，完全可以实现严谨推理深度与人类交互体验的协同增益。

6 研究进展与关键争论：RLVR 究竟提升了什么

6.1 推理能力的评估

随着以 DeepSeek-R1 为代表的 RLVR 模型在各大数学与编程榜单上取得突破性进展，学术界迅速转向了一个更为本质的科学追问：经过可验证奖励强化学习训练后，模型在基准测试上的大幅涨分，究竟意味着模型真正习得了超越预训练基座的新推理能力，还是仅仅把基座模型原本就已经会做、但单次采样不易抽中的正确解法集中到了高概率区域？要客观回答这一问题，首先必须审视推理能力本身的量化评估方法，因为不同的评测指标测量的是策略分布截然不同的统计侧面[14-15,2]。

在常规模型评测中，最广泛使用的指标是单次采样准确率（Pass@1，通常在对多条独立采样取均值意义下报告以降低评估方差）。Pass@1 度量的是模型在单次生成尝试中直接命中正确答案的期望概率，直接反映了模型在实际部署时的单次推理可靠性与采样效率。然而，Pass@1 无法区分“从完全不会变为会做”与“将原本 5% 的答对概率提高到 80%”这两种截然不同的变化。为了探测一个策略模型潜在的推理能力上限（Capability Boundary），Yue 等人[14]与 Wen 等人[15]系统引入了代码生成领域经典的多次采样通过率指标 Pass@k：针对同一问题提示 q 独立采样 k 条候选回复，只要其中至少存在一条回复最终答案正确，即判定模型在该预算 k 下能够解决该问题。为了消除直接抽样 k 次带来的随机波动，实际评测时通常先针对每道题生成总数 G（$G \geq k$）条回复，统计其中最终答案正确的样本个数 $C = \sum_{i=1}^{G} I_{\text{Ans}}(a_i)$，再采用无偏组合估计量计算 Pass@$k$[14-15]：

$$\text{Pass@}k(q) = 1 - \frac{\binom{G-C}{k}}{\binom{G}{k}}, \qquad \text{CoT-Pass@}k(q) = 1 - \frac{\binom{G-D}{k}}{\binom{G}{k}}. \tag{18}$$

当采样次数 k 较小时（如 $k = 1$），Pass@k 反映模型的日常生成效率；而当 k 增大到数百乃至上千（如 $k = 128, 256, 1024$）时，Pass@k 则刻画了模型输出分布支撑集（Support）所能触及的潜在解题广度。

然而，Wen 等人[15]通过深入人工核查发现，直接照搬仅检查最终答案对错的传统 Pass@k（式 (18) 左式）来评估大采样预算下的数学基座模型，会产生严重的系统性高估偏差。原因在

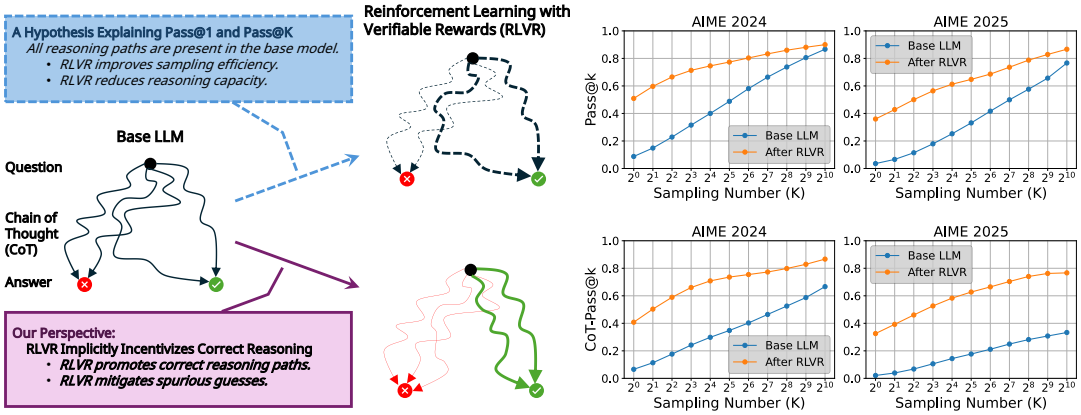


图 21： 传统答案级 Pass@K 假设（左上）与兼顾推导逻辑正确性的 CoT-Pass@K 评估视角（左下）对比，以及两者在 AIME 2024/2025 上的实测曲线差异（右）：基座模型在大量重复采样时常通过错误的中间推导凑巧蒙对简单数值答案，导致传统 Pass@K 虚高；引入同时检验中间思维链与最终答案的 CoT-Pass@K 后，RLVR 模型在大采样次数下展现出持续领先的真实推理边界（原图引自文献[15]）。

于，许多高难度数学竞赛题的最终答案形式极为简单（例如 AIME 竞赛规定所有题目答案均为 000 至 999 之间的整数）：当对一个未经对齐的预训练基座模型强行独立采样 1024 次时，模型会生成五花八门包含严重逻辑跳跃、公式张冠李戴甚至中途算错的思维链，但只要其中哪怕有一次在错误的推导末尾凑巧输出了目标整数，传统 Pass@k 就会认定“基座模型本来就会解这道题”[15]。

为了剥离这种“错误推导凑巧猜中答案”的虚假通过信号，Wen 等人提出了式 (18) 右式所示的精细化评估指标 CoT-Pass@k[15]，其概念对比见图 21。在式 (18) 右式中，$D = \sum_{i=1}^{G} I_{\text{CoT}}(c_i) \cdot I_{\text{Ans}}(a_i)$ 表示在 G 次采样中，不仅最终答案 a_i 正确（$I_{\text{Ans}}(a_i) = 1$），而且中间思维链推导过程 c_i 同样经过严格逻辑核验确认为无关键谬误（$I_{\text{CoT}}(c_i) = 1$，实践中借助强推理验证模型多次独立核查并辅以人工抽检）的样本总数。与之形成鲜明对照的是代码生成任务：由于一段程序必须完整通过数十组严密的输入输出测试样例才能判为正确，盲目猜测通过所有测试的概率几乎为零，因此代码基准（如无数据污染的 LiveCodeBench）上的传统执行 Pass@k 天然具备高可信度[15]。此外，第 4.4 节提及的基座提示模板匹配效应[12]与测试集发布时间早于预训练截断日期引发的数据污染问题[15]也表明，唯有同时选用无污染高难度基准、恰当的初始提示模板以及剔除猜题干扰的 CoT-Pass@k 指标，才能对 RLVR 的真实作用做出科学评判。

6.2 采样效率提升与推理能力边界扩展之争

依托上述多维评估体系，近年来围绕“RLVR 究竟提升了什么”展开了后训练领域最核心的一场学术争论，研究结论经历了从“分布锐化论”到“有条件的能力边界扩展论”的逐步深化[14,16,15,2]。

争论的起点是 Yue 等人发表的系统性实证研究《Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?》[14]。作者在涵盖 Qwen2.5、Llama-3.1 与 DeepSeekMath 等多个模型家族以及数学、代码生成、视觉多模态推理的广泛基

准上，对比了基座模型与主流开源 RLVR 训练后模型从 $k = 1$ 到 $k = 1024$ 的完整 Pass@k 曲线。

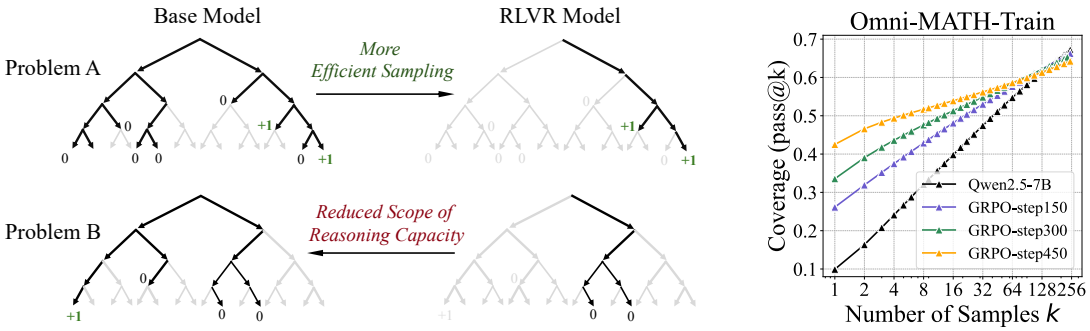


图 22: Yue 等人关于常规 RLVR 压缩搜索分布广度的核心观测：左图示意 RLVR 增强了已有正确路径的采样概率但缩小了整体覆盖范围；右图展示在奥数基准 Omni-MATH 上，RLVR 模型虽在小 k 值（如 Pass@1）上大幅领先基座模型，但随着采样数 k 增至 128 与 256，基座模型的通过率迅速追上并反超 RLVR 模型（原图引自文献[14]）。

如图 22 所示，实验呈现出一个高度一致的反直觉规律：当 $k = 1$ 时，RLVR 模型的准确率显著高于基座模型；但随着 k 不断增大，基座模型的 Pass@k 曲线以更陡峭的斜率快速攀升，通常在 $k = 64$ 至 256 之间便追平并反超了经过强化学习训练的模型[14]。更进一步的子集归属分析显示，RLVR 模型能够解出的题目几乎完全包含在基座模型多次采样可解题目的子集之内；相比之下，用更强大的外部模型轨迹对基座执行知识蒸馏（Distillation），则能在所有 k 值上全面抬高整条 Pass@k 曲线。据此，Yue 等人提出“采样效率提升假说”：当前 RLVR 并未让模型习得超越预训练先验范围的新推理知识，而仅仅是将原本分散在广阔输出空间中的概率质量集中到了基座模型本就存在的正确路径上，即以牺牲输出分布多样性与大 k 覆盖上限为代价，换取了单次采样的准确性[14]。

这一尖锐结论迅速激发了后续更为深入的反驳与修正研究，其中最具代表性的是 Liu 等人提出的延长强化学习框架 ProRL[16] 与 Wen 等人的隐式正确推理激励理论[15]。他们通过严密实验指出，Yue 等人之所以观测到大 k 下能力边界收缩，主要受制于三项实验设定局限：一是评测数学题时未剔除基座模型在千次采样下的凑巧猜对现象；二是所考察的开源 RLVR 模型大多只在单一数学领域上训练了寥寥数百步便提前终止，尚未进入深层探索阶段；三是所选数学基准与预训练语料重合度极高，基座模型初始大 k 通过率本就接近饱和[16,15]。

当消除上述三项混淆因素后，实验图景发生了根本改观。首先，在评估维度上，Wen 等人[15]证明（见图 21 右图），一旦改用严格核验推导过程的 CoT-Pass@k 并在无预训练污染的 AIME 2025 及高难度代码基准 LiveCodeBench v1–v6 上评测，经过充分训练的 RLVR 模型（如 DAPO-Qwen-32B 与 AceReason-Nemotron-7B）即便在 $k = 1024$ 处依然与基座模型保持着显著且稳定的正向差距。为了从理论上解释“为什么只奖励最终答案对错就能促使中间推导变正确”，Wen 等人建立了基于“逻辑先验（Logic Prior）”的梯度定理[15]：只要预训练赋予模型

最基本的逻辑区分先验，使得正确思维链导出正确答案的条件概率严格高于错误思维链凑巧蒙对答案的条件概率，即

$$\alpha \triangleq P\big(I_{\mathrm{Ans}}(a)=1 \,\big|\, I_{\mathrm{CoT}}(c)=1\big) > P\big(I_{\mathrm{Ans}}(a)=1 \,\big|\, I_{\mathrm{CoT}}(c)=0\big) \triangleq \beta_{\mathrm{guess}}, \tag{19}$$

那么在任意可学习提示组上，正确思维链获得的期望 GRPO 优势严格为正（$\mathbb{E}[\hat{A}(y) \mid I_{\mathrm{CoT}}(c)=1] > 0$），错误思维链的期望优势严格为负（$\mathbb{E}[\hat{A}(y) \mid I_{\mathrm{CoT}}(c)=0] < 0$）。这意味着单步策略梯度更新必然单调推高生成严密逻辑推导链的概率并压低胡乱猜测的概率；将 RLVR 训练后的思维链提取出来重新微调原始基座，能够复现出基座自身采样数据根本无法企及的测试集泛化能力，直接证实推理过程质量发生了质的跃升[15]。

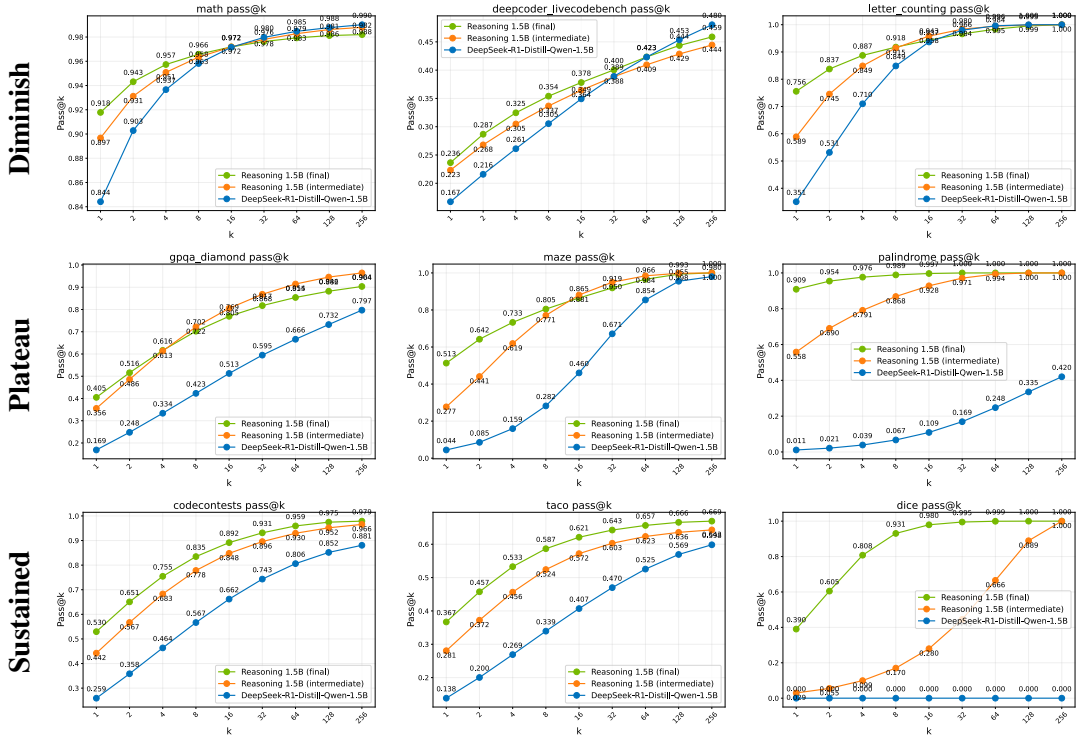


图 23： ProRL 在超过两千步长程多领域强化学习下揭示的三类 Pass@k 边界演化形态：第一行（Diminish）对应基座原本已高度擅长的常规数学等任务，强化学习主要收紧分布导致大 k 略降；第二行（Plateau）对应早期即达到能力拓展上限的任务；第三行（Sustained）对应复杂竞赛编程与分布外逻辑谜题（如右下角骰子推理任务基座在 $k=256$ 下通过率恒为 0，而长程 RL 模型达到 1.0），清晰证实长程 RLVR 能够实质性开辟基座无法触及的全新求解空间（原图引自文献[16]）。

其次，在任务先验与训练步数维度上，ProRL[16]在涵盖数学、代码、科学推理、逻辑谜题与指令遵循的 13.6 万道多领域题目上将 15 亿参数模型持续训练超过 2000 步，统一调和了此前的矛盾观测。如图 23 所示，不同任务在长程 RLVR 下的 Pass@k 变化并非单一模式，而是分化为边界收缩（Diminish）、早期饱和（Plateau）与持续扩展（Sustained）三种清晰形态[16]：在基座模型预训练覆盖充分、初始 Pass@128 本就极高的常规数学任务上，分布锐化效应占主导，大 k 分数略有回落；但在基座模型初始能力薄弱、与预训练语料重叠度低（创造性指数 Creativity Index 更高）的复杂代码竞赛与逻辑组合谜题上，RLVR 展现出显著的边界扩展效应

——甚至在多类基座模型连续抽样 256 次通过率恒为 0% 的全新任务及分布外测试任务上，经过长程 ProRL 训练的模型取得了接近 100% 的通过率[16]。综合两派证据可以得出公允的科学结论：RLVR 虽然无法凭空捏造预训练词表与基础常识之外的全新事实知识，但当基座模型已经具备原子级推理原语且任务留有充足组合空间时，长程、高质量的 RLVR 完全能够学会将这些原子技能按全新方式长程组合，从而实质性扩展复杂问题求解的能力边界。

6.3 Continuous Learning 的条件：探索、训练时长与隐式课程

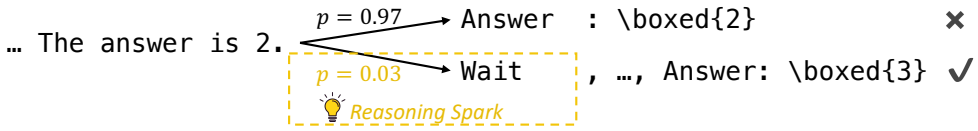
上述争论进一步引出了一个决定实际训练成败的关键问题：为什么普通 RLVR 训练往往在几百步后就因分布固化和梯度消失而停滞，而在另一些设定下模型却能维持数千步的持续强化学习精进？需要说明的是，此处目录所称的 Continuous Learning，在推理模型强化学习语境下特指模型在长程训练过程中不发生性能坍缩、随训练算力投入持续提升推理表现的持续强化学习优化（Prolonged RL），而非传统多任务序列学习中旨在克服灾难性遗忘的连续学习[16,18,17]。综合最新理论与大规模实证研究，实现这种长程持续学习必须同时满足词元级有效探索维持、充足训练时长配合参考基准动态重置以及平滑混合难度诱导隐式课程这三项核心条件。

第一个条件是精准保护有意义的低概率探索词元，而非盲目推高全局策略熵。如前文所述，长程 RLVR 停滞的最典型征兆是策略熵快速归零，但 Huang 等人在 ACL 2026 发表的大规模实证研究[17]揭示了一个反常现象：如果在 GRPO 损失中简单加上传统的全局最大熵奖励项（Entropy Bonus），模型不仅没有变得更能探索，反而比原始 GRPO 更快发生训练崩溃（见图 24 子图 b）。为什么全局增熵会适得其反？通过对预测词表尾部分布的细致统计，作者发现长思维链之所以能够退出受阻推导并转向新的候选解法分支，关键依赖于诸如“wait”“however”“perhaps”这类触发反思与路径切换的低概率探索词元；然而在词表概率极低的长尾末端，除了这些有语义价值的探索词元外，还分布着数以万计与当前数学上下文毫无关系的纯噪声词元（如无关名词“cost”“fine”）[17]。标准 GRPO 在遭遇负优势样本时会无差别地将有价值的低概率探索词元压制到零；而无选择性的全局熵损失则会把大量无关噪声词元的采样概率大幅抬高（图 24 子图 d），直接破坏推理连贯性。

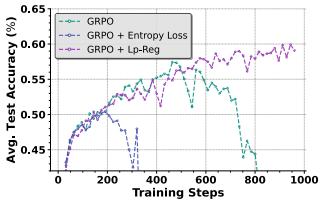
利用“有意义探索词元的预测概率虽低但仍系统性高于纯背景噪声词元”这一内在统计区分度，Huang 等人提出了低概率正则化方法 Lp-Reg[17]。该方法首先采用自适应阈值 $\tau = \kappa \max_{o'} \pi_\theta(o' \mid s_t)$ 滤除低于该阈值的极低概率噪声词元，对剩余有效词元重归一化构造去噪代理分布 π_{proxy}；随后仅对同时满足当前概率偏低、属于去噪有效集且本轮处于负优势更新（$\hat{A}_{i,t} < 0$）的活跃集合 Ω_t 内词元施加前向 KL 散度保护项[17]：

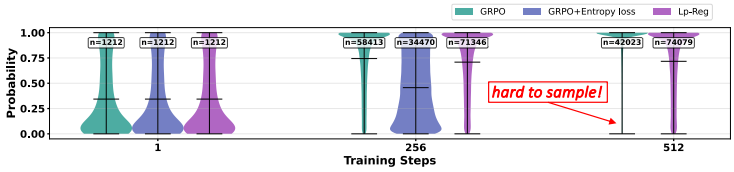
$$\mathcal{R}_{\text{Lp-Reg}}(\theta) = \beta_{\text{lp}}\, \mathbb{I}\big[(s_t, a_t) \in \Omega_t\big] \cdot D_{\text{KL}}\big(\pi_{\text{proxy}}(\cdot \mid s_t) \,\|\, \pi_\theta(\cdot \mid s_t)\big). \tag{20}$$

由于前向 KL 散度在 $\pi_\theta(o \mid s_t) \to 0$ 时会产生趋于无穷大的排斥梯度，式 (20) 在不干扰正向奖励更新、也不放大底层噪声的前提下，精准阻止了有价值探索词元被负样本彻底消除，从而在超过 3000 个训练步（累计逾 8 万 GPU 小时）的同策略训练中维持了“先收敛基础模式、再回升探索、最终平稳演进”的持续性能扩展[17]。

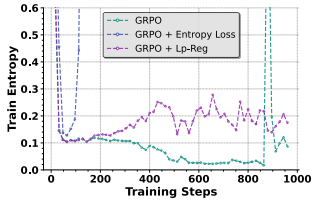


(a) Reasoning Sparks: low-probability exploratory tokens that initiate potential diverse reasoning paths.

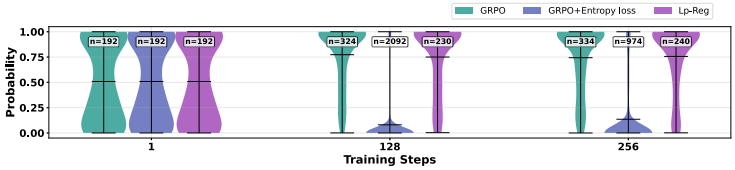




(c) Aggregated distribution of observed sampling probabilities for exploratory tokens (e.g., “wait”, “however”). “n” represents sampling number.



(b) Training Dynamics



(d) Aggregated distribution of observed sampling probabilities for meaningless tokens (e.g., “cost”, “fine”). “n” represents sampling number.

图 24： 选择性保护低概率探索词元对于维持持续强化学习的关键作用：（a）低概率反思词元触发推理分支修正示例；（b）标准 GRPO 因熵衰减陷入平台，而无差别全局熵损失反而加速崩溃，唯独 Lp-Reg 实现持续准确率提升；（c–d）Lp-Reg 在训练中精准保留了有语义价值的探索词元采样概率，同时避免了全局熵损失对无关噪声词元的错误放大（原图引自文献[17]）。

第二个条件是突破短程步数限制，并在长程训练中配合动态参考策略重置机制。ProRL[16]的研究表明，模型从掌握浅层格式调整到真正重组深层多步推理策略，往往需要跨越上千步乃至两千步以上的持续迭代更新。但在漫长的训练周期内，固定不变的初始参考策略 π_{ref} 会引发新的矛盾：如第 2.3 节所述，完全去掉 KL 惩罚容易导致已具备良好思维链基础的模型过早丢失分布多样性，而如果一直以最初的检查点作为参考分布基准，随着在线策略不断演化，KL 散度惩罚项将在总损失中占据越来越大的比重，最终过度限制参数更新步长使后期训练陷入停滞[16]。对此，ProRL 引入了周期性参考策略硬重置（Reference Policy Reset）机制：每当监测到验证集性能进入平台期时，便直接将参考策略更新为当前最新的在线策略快照，并同步重新初始化优化器动量状态[16]。这一操作在局部维持了 KL 分布稳定约束的同时，允许策略分布通过多轮分阶段推进不断向高阶解空间深处拓展。

第三个也是从数据动力学角度最为关键的条件，是训练数据难度谱系的平滑连续性所诱导的“隐式课程（Implicit Curriculum）”。长期受到理论界关注的一个核心问题是：对于需要连续正确执行 L 步组合操作的长跨度推理任务，初始近似均匀的注意力机制面对终端二值结果奖励时，正确轨迹的采样概率与策略梯度模长均以 $d^{-\Omega(L)}$ 的指数级速度衰减为零（形成指数级平坦梯度区）[18]；既然初始梯度几乎为零，现实中并未人工按难度排序题目的大规模 RLVR 为何没有停留在零梯度初始区，反而能逐步攻克长跨度难题？

Huang 等人（2026）[18]借助有限群上的傅里叶分析工具，在具备预训练单步原子技能的 Transformer 模型上严格证明了混合难度分布下的训练动力学定理，阐明了这一现象的内在机理。理论与实证结果（见图 25）共同表明：当训练数据集自然包含从短跨度到长跨度的混合

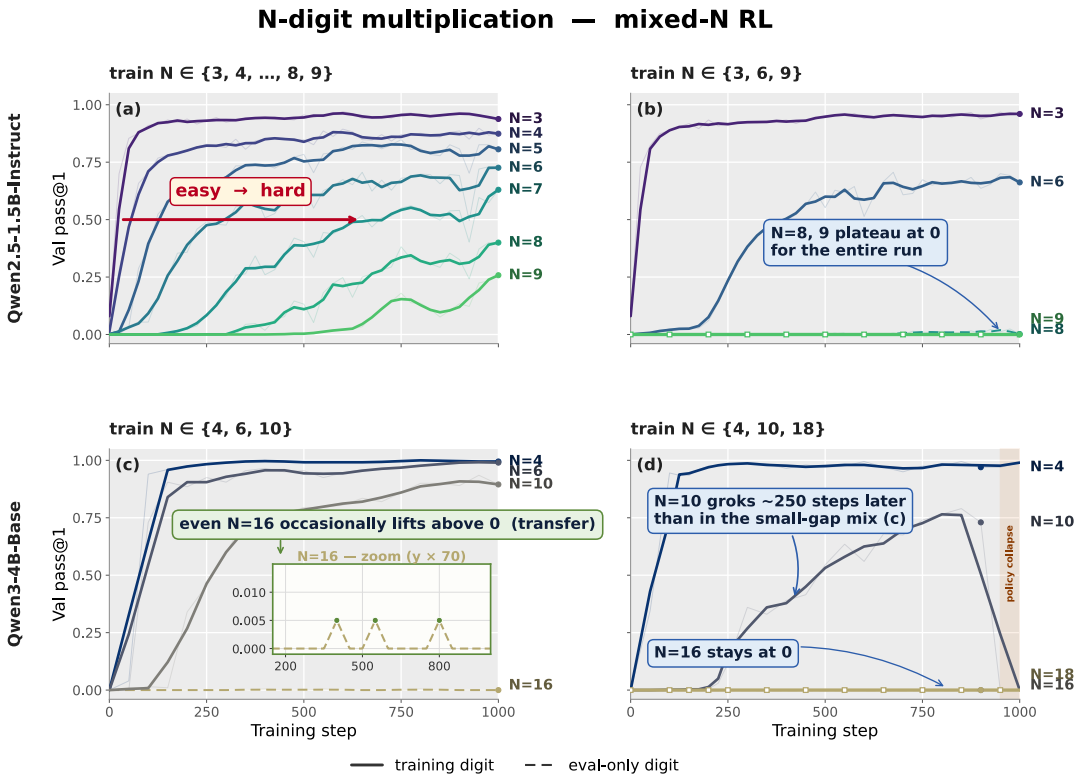


图 25: 混合难度训练数据在无任何人工显式调度下自发诱导由易到难隐式课程的实证规律（以多位数乘法 $N \times N$ 为例，N 越大推理跨度越长）：当训练集包含连续平滑难度阶梯 $\{3, 4, \ldots, 9\}$ 或较小难度间隔 $\{4, 6, 10\}$ 时（图 a、c），模型依次快速掌握简单位数并连续带动高难度位数平稳突破；而当训练难度分布稀疏、跨度过大如 $\{3, 6, 9\}$ 或 $\{4, 10, 18\}$ 时（图 b、d），高难度任务会陷入漫长零分平台期乃至出现大幅延迟的收敛突变或持续停滞（原图引自文献[18]）。

难度样本 $\{L_1, L_2, \ldots, L_K\}$ 时，无需任何外部显式课程调度，策略梯度优化会自发涌现出由易到难的隐式课程[18]。具体而言，处于临界短跨度以内的简单题目首先获得非零终端奖励并率先收敛，其梯度更新在持续锐化模型内部注意力关联表征的过程中，会同步抬高相邻稍难问题 L_{k+1} 的偶然成功概率，使其脱离指数平坦区进入有效学习前沿。尤为重要的是，这种自发课程的运转效率严格取决于相邻难度步长比 $R = L_{k+1}/L_k$：当训练数据的难度谱足够稠密平滑（即 $R = O(1)$）时，简单任务在尚未完全饱和前便已将有效梯度平稳传递给下一难度层级，训练始终保持在模型当前“能力边缘（Edge of Competence）”连续推进；反之，若数据集中缺少中间过渡难度导致难度断层过大（$R \gg 1$），简单任务早已满分饱和（失去梯度），而高难任务仍处于随机猜题区，模型只能依靠简单任务残余的微弱特征锐化经历极其漫长的零奖励停滞平台，之后才可能突然触发文献中称为延迟泛化（Grokking）的陡峭相变跃迁，甚至长期停滞在零分[18]。这一理论不仅从数学上解释了 RLVR 训练中常见的长平台后突变现象，也指明了持续强化学习在数据侧的关键原则：构建覆盖连续难度梯度并实时聚焦能力前沿的训练题库，与改进优化算法同等重要。

6.4 从确定性验证到更广泛任务的奖励设计

尽管以符号计算引擎和代码单元测试为核心的确定性规则验证器在数学与编程领域取得了巨大成功，但如果大语言模型的强化学习后训练只能停留在具备封闭形式解或可执行代码的狭窄领域，其通往通用复杂科学推理与现实决策辅助的道路仍将受到明显限制。在临床医学鉴别诊断、法律条文适用分析、宏观经济学机制推演、心理学实验设计以及人文社科综合论述等更为广阔的知识密集型领域中，问题的解答天然呈现为自由文本形式（Free-Form Answers），既无法放进编译器运行，也无法通过几条正则表达式或符号化简规则穷尽所有语义等价的正确表述[19,2]。

更为严峻的是，Su 等人在 ACL 2026 发表的跨学科大规模实证研究[19]揭示了一个反直觉的退化现象：当试图将传统的精确字符串或规则匹配验证器强行推广到涵盖医学、法学、经济学、工程学等 48 个一级学科的大学专业简答基准 ExamQA 上时，随着多领域自由问答训练数据量从 2 万条扩充至 10 万条，规则驱动 RLVR 训练出的策略模型准确率不仅没有提升，反而从 26.2% 一路下降至 16.9%（见图 27 左图红色折线）[19]。其根源在于，自由文本领域中僵硬规则的假阴性率极高，大量推理严密但措辞与标准答案表面不一致的优质回答被误判为零分，迫使模型在更大规模数据上放弃实质性学科推理而去迎合零散的局部字面匹配，从而严重损毁了跨领域泛化能力。

那么，一旦越出严格结构化任务边界，难道我们只能退回第 3 节那种依赖高昂人工偏好标注且极易遭受奖励欺骗的传统 RLHF 奖励模型吗？Su 等人[19]提出了一条兼顾客观真值依据与语义灵活性的改进思路：传统无参考奖励模型之所以在专业领域不可靠，是因为要求模型在没有任何标准答案对照的情况下直接评判高深专业问题的对错；但如果我们为每道专业问题配备一份专家撰写的标准参考答案（Reference Answer）a，将验证器的任务从“开放式质量打分”转化为“对照给定标准答案 a 核查模型最终结论 y^T 是否在专业语义上等价正确”，那么现代强指令语言模型与人类专家评判之间便能达到极高的一致性（实测跨学科科恩一致性系数 Cohen's $\kappa > 0.81$，高校专业学科上超过 0.87）[19]。

基于这一核心观察，Su 等人构建了如图 26 所示的基于参考答案的跨领域生成式验证 RLVR 框架[19]。该框架不再输出生硬的离散 0/1 采样值，而是读取轻量级生成式验证模型 π_ϕ 在给定问题 x、专家参考答案 a 与待测回复结论行 y^T 条件下，对正确判定词元“1”与错误判定词元“0”的预测概率，构造归一化连续软概率奖励（Soft Probabilistic Reward）[19]：

$$r_\phi(x, a, y_i) = \frac{\pi_\phi\big(1 \mid x, a, y_i^T\big)}{\pi_\phi\big(0 \mid x, a, y_i^T\big) + \pi_\phi\big(1 \mid x, a, y_i^T\big)} \in [0, 1]. \tag{21}$$

为了消除在线强化学习中频繁调用百亿级巨型评判模型的高昂算力成本，作者巧妙收集早期强化学习探索阶段产生的包含各种格式噪声与中间水平回答的真实轨迹三元组，用 720 亿参数教师模型离线打标后，通过监督微调蒸馏出一个紧凑高效的 70 亿参数专用验证器 RM-7B，全程无需额外雇佣特定领域人工标注偏好[19]。

如图 27 所示，这一奖励设计演进展现出三方面重要价值[19]。第一，连续概率软奖励在所有测试的强化学习算法（REINFORCE、留一法基线策略梯度 RLOO 与 GRPO）及所有学科大

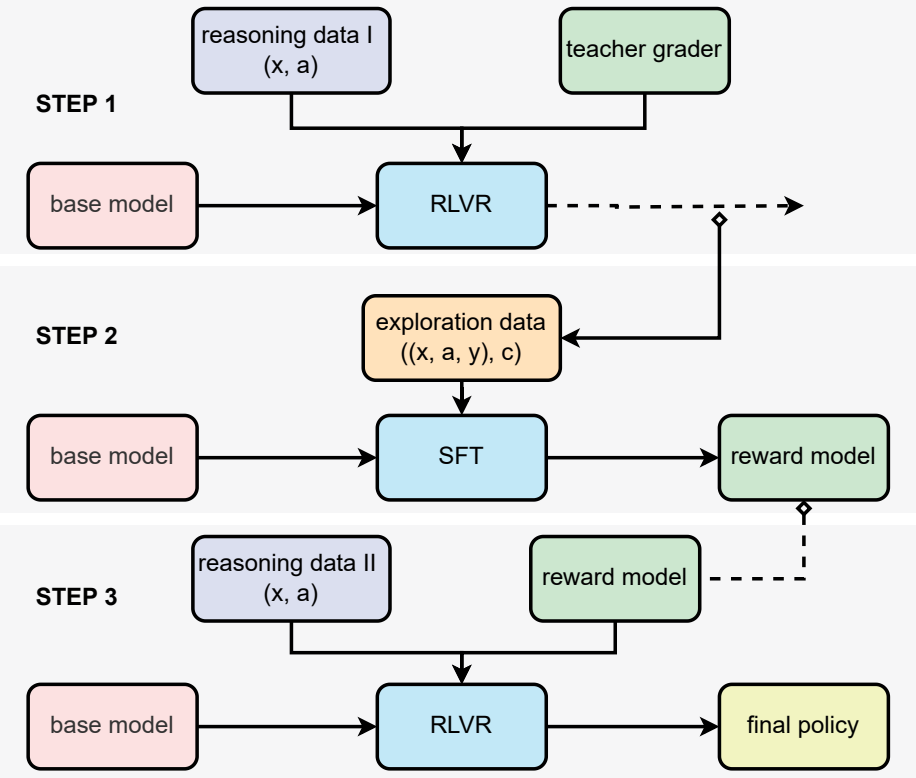


图 26: 将 RLVR 拓展至跨学科自由文本推理领域的生成式参考验证框架：第一阶段利用强教师评判模型对照专家参考答案 a 引导初步探索采样；第二阶段利用探索过程中收集的多样化带噪轨迹 (x, a, y) 与一致性标签 c 蒸馏训练轻量级 70 亿参数跨领域生成式验证器；第三阶段利用该验证器输出连续概率软奖励驱动大规模 RLVR 训练（原图引自文献[19]）。

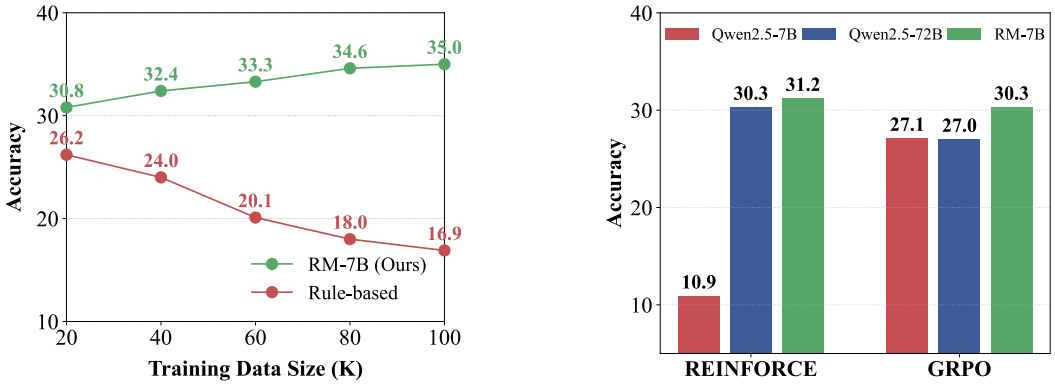


图 27: 跨学科自由形式推理任务中基于参考答案的生成式软奖励验证器（RM-7B）与规则奖励及不同规模通用模型验证器的实证对比：左图显示随着训练数据从 2 万扩展至 10 万，规则奖励性能持续恶化，而 RM-7B 驱动的 RLVR 准确率单调稳步提升；右图显示经探索轨迹蒸馏的紧凑型 RM-7B 在 REINFORCE 与 GRPO 算法下媲美乃至超越十倍参数量的 72B 教师验证器（原图引自文献[19]）。

类（尤其是答案存在部分正确或表述层次差异的人文与社会科学）上，均稳定超越离散二值判定 2.2% 至 5.0%，证明细粒度置信度反馈能够为非结构化领域提供更平滑有效的策略梯度。第二，当训练数据从 2 万扩充至 10 万条时，RM-7B 驱动的策略准确率从 30.8% 稳步增长至 35.0%，

彻底扭转了规则验证器的规模退化困境，甚至使一个 70 亿参数的策略模型在 48 学科评测上大幅超越了十倍体量的 Qwen2.5-72B-Instruct（领先 +8.6%）与 DeepSeek-R1-Distill-Qwen-32B（领先 +9.5%），并在多学科综合基准 MMLU-Pro、研究生级科学问答基准 GPQA 等七个分布外测试集上取得优异迁移效果。第三，从更宏观的前沿视野来看[2]，以参考答案为客观对照的生成式软验证器、先对评分细则展开显式推理再给出评价的推理型奖励模型（Reasoning Reward Models），以及通过真实软件仓库编译、网页交互与科学实验反馈提供多轮环境信号的智能体强化学习（Agentic RL），正在共同消解“刚性程序规则验证”与“纯主观神经偏好模型”之间的二元对立，将高可靠性的强化学习稳步推向更加贴近真实世界复杂形态的广阔任务空间。

7 总结与展望

回顾大语言模型强化学习后训练从 RLHF 到 RLVR 的完整演进历程，一条清晰的内在逻辑贯穿始终：自回归预训练通过海量语料上的下一词元似然最大化为模型奠定了广博的知识表征与原子推理先验，而后训练阶段的核心使命，则是设计既符合目标任务本质、又能承受优化压力而不失真的反馈信号，引导模型在序列决策空间中自主重塑输出分布[1,3,2]。在这一演进脉络的起点上，针对日常开放域交互任务难以用确定性程序定义优劣的难题，RLHF 借助成对人类偏好比较与 Bradley-Terry 统计建模，首次打通了从人类主观判断到大规模语言模型策略梯度更新的闭环[4,1]；随后 DPO 利用 KL 正则化目标的闭式最优解消除了显式奖励建模与在线采样负担，使偏好对齐成为现代开源模型的普惠基础组件[5]。然而，受制于人类专家标注在复杂专业任务上的高昂成本，以及参数化代理奖励模型在分布偏移下必然触发的过度优化与奖励欺骗定律[8,10]，单纯依赖主观偏好拟合的路线难以通过持续扩大强化学习算力来攻克长跨度逻辑难题。

正是在克服代理奖励失真的直接驱动下，RLVR 通过回归客观真值检验实现了后训练范式的关键跃迁[6-7,3]。依托符号数学核验与代码单元测试等零拟合误差的确定性验证函数，配合省去庞大价值网络的群组相对策略优化（GRPO）[7]以及针对熵坍缩、零优势退化和长度归一化偏差的系统性修正（如 DAPO 与 Dr. GRPO）[11-12]，大语言模型首次展现出仅凭终端结果反馈即可自发演化出长思维链、自我验证与路径回溯等高阶推理行为的能力[3]。进一步围绕“RLVR 究竟提升了什么”的深入争论表明，单次采样效率提升与潜在推理边界扩展并非非此即彼的对立属性[14,16,15]：只要基座模型在预训练中掌握了必要的原子逻辑先验，同时在训练中满足精准保护低概率探索词元[17]、维持足够训练步数并动态更新参考分布基准[16]、以及构建连续平滑的混合难度数据谱系以触发由易到难的隐式课程传递[18]，稀疏的结果级强化学习便能超越单纯的概率锐化，实质性拓展复杂组合推理的能力上限；而将其与负责塑造表达可读性、通用指令遵循及安全边界的 RLHF 或 DPO 分阶段协同整合，则构成了当前旗舰级推理与对话通用模型的标准后训练范式[6,3]。

展望未来，大语言模型强化学习后训练仍处于快速演进之中，以下四个方向有望成为下一阶段突破的关键着力点。第一，在奖励与验证机制层面，研究重心正加速从单一回合的数学与封闭代码题，迈向更广阔的跨学科专业领域与开放式多轮交互环境[19,2]。一方面，如何结合专

家参考答案、结构化评分细则（Rubrics）与具备显式先思考后评判能力的生成式奖励模型，在医学、法学、科学研究与工程设计等自由文本场景中提供既细腻又抗策略投机的软验证信号，仍需深入探索静态蒸馏之外的策略—验证器协同演化机制[19,2]；另一方面，在软件仓库级修复、网页信息检索与多模态工具操作等长周期智能体（Agentic RL）任务中，将真实外部环境的执行状态反馈转化为多步密集可验证奖励，将是释放现实世界生产力价值的重要途径[2]。

第二，在推理效率与测试时计算控制层面，克服无谓的长度膨胀与"过度思考"正变得日益紧迫[12,2]。当前长链推理模型面对简单算术或常识问题时仍常耗费数千词元反复自检，带来高昂的线上推理延迟与能耗开销。未来不仅需要在优化器层面普遍落实无长度偏差的梯度估计[12]，更需要在奖励塑形与模型架构层面引入按题目真实复杂度自适应分配思考预算的机制，乃至探索在连续隐状态空间（Latent Space）内完成紧凑推理计算而仅按需输出简洁人类可读解释的新型训练范式[2]。

第三，在预训练先验、数据课程与强化学习的联合设计层面，越来越多的证据表明强化学习的能力上限深刻依赖于基座模型预训练阶段的领域知识密度与逻辑原语质量[12,18]。未来的模型研发将不再把预训练、监督微调与强化学习视作割裂的串联工序，而是通过在线监测模型当前的"能力边缘"，动态合成或检索难度恰处于可学习前沿的过渡任务以消除隐式课程断层[18]，并在预训练阶段前瞻性注入有利于后续探索分支涌现的多样化推理语料[12,2]。第四，在大规模系统基础设施与持续演化算法层面，随着单次强化学习训练跨度向数千步、数万词元上下文乃至多轮环境交互延伸，异构采样生成与参数梯度更新之间的负载不均衡与策略滞后（Off-Policyness）矛盾愈发突出[11,17,2]。发展支持异步流式采样、精细化词元级分布正则化与跨周期稳定持续学习的下一代强化学习系统，同时将基于客观环境验证的能力进化（RLVR）与基于多元人类价值规范的安全对齐（RLHF）更加紧密、稳健地统一在同一理论与工程框架之下，将持续推动大语言模型向更可靠、更高效、更具通用求解深度的方向迈进。

参考文献

[1] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[A/OL]. 2022. arXiv: 2203.02155v1. https://arxiv.org/abs/2203.02155.

[2] ZHANG K, ZUO Y, HE B, et al. A Survey of Reinforcement Learning for Large Reasoning Models [A/OL]. 2025. arXiv: 2509.08827v3. https://arxiv.org/abs/2509.08827.

[3] DEEPSEEK-AI, GUO D, YANG D, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[A/OL]. 2025. arXiv: 2501.12948v2. https://arxiv.org/abs/2501.12948.

[4] CHRISTIANO P, LEIKE J, BROWN T B, et al. Deep reinforcement learning from human preferences[A/OL]. 2017. arXiv: 1706.03741v4. https://arxiv.org/abs/1706.03741.

[5] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[A/OL]. 2023. arXiv: 2305.18290v3. https://arxiv.org/abs/2305.18290.

[6] LAMBERT N, MORRISON J, PYATKIN V, et al. Tulu 3: Pushing Frontiers in Open Language Model Post-Training[A/OL]. 2024. arXiv: 2411.15124v5. https://arxiv.org/abs/2411.15124.

[7] SHAO Z, WANG P, ZHU Q, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models[A/OL]. 2024. arXiv: 2402.03300v3. https://arxiv.org/abs/2402.03300.

[8] GAO L, SCHULMAN J, HILTON J. Scaling Laws for Reward Model Overoptimization[A/OL]. 2022. arXiv: 2210.10760v1. https://arxiv.org/abs/2210.10760.

[9] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms [A/OL]. 2017. arXiv: 1707.06347v2. https://arxiv.org/abs/1707.06347.

[10] LIU P, SHI C, SUN W W. Reinforcement Learning from Human Feedback: A Statistical Perspective [A/OL]. 2026. arXiv: 2604.02507v1. https://arxiv.org/abs/2604.02507.

[11] YU Q, ZHANG Z, ZHU R, et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale[A/OL]. 2025. arXiv: 2503.14476v2. https://arxiv.org/abs/2503.14476.

[12] LIU Z, CHEN C, LI W, et al. Understanding R1-Zero-Like Training: A Critical Perspective[A/OL]. 2025. arXiv: 2503.20783v2. https://arxiv.org/abs/2503.20783.

[13] LIGHTMAN H, KOSARAJU V, BURDA Y, et al. Let's Verify Step by Step[A/OL]. 2023. arXiv: 2305.20050v1. https://arxiv.org/abs/2305.20050.

[14] YUE Y, CHEN Z, LU R, et al. Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?[A/OL]. 2025. arXiv: 2504.13837v5. https://arxiv.org/abs/2504.13837.

[15] WEN X, LIU Z, ZHENG S, et al. Reinforcement Learning with Verifiable Rewards Implicitly Incentivizes Correct Reasoning in Base LLMs[A/OL]. 2025. arXiv: 2506.14245v2. https://arxiv.org/abs/2506.14245.

[16] LIU M, DIAO S, LU X, et al. ProRL: Prolonged Reinforcement Learning Expands Reasoning Boundaries in Large Language Models[A/OL]. 2025. arXiv: 2505.24864v1. https://arxiv.org/abs/2505.24864.

[17] HUANG G, XU T, WANG M, et al. Low-probability Tokens Sustain Exploration in Reinforcement Learning with Verifiable Reward[C/OL]//Findings of the Association for Computational Linguistics: ACL 2026. 2026: 24158-24188. https://aclanthology.org/2026.findings-acl.1209/. DOI: 10.18653/v1/2026.findings-acl.1209.

[18] HUANG Y, WEN Z, CHI Y, et al. On the Emergence of Implicit Curriculum in RLVR Learning Dynamics[A/OL]. 2026. arXiv: 2602.14872v3. https://arxiv.org/abs/2602.14872.

[19] SU Y, YU D, SONG L, et al. Crossing the Reward Bridge: Expanding Reinforcement Learning with Verifiable Rewards Across Diverse Domains[C/OL]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2026: 3872-3892. https://aclanthology.org/2026.acl-long.178/. DOI: 10.18653/v1/2026.acl-long.178.